ENEM 2023 · EXPERIMENTO COM MODELOS DE IA

Previsão da nota de Linguagens do ENEM

Variável alvo: NU_NOTA_LC, a nota de Linguagens, Códigos e suas Tecnologias

Árvore de Decisão | Stacking | KNN | Boosting

BASE DE DADOS

Variável alvo e participantes

Variável alvo: **NU_NOTA_LC**, a nota de Linguagens, Códigos e suas Tecnologias

2.822.643
participantes elegíveis, a base completa

2.258.114
em desenvolvimento

564.529
reservados para teste (semente 42)

15
variáveis: 12 originais e 3 criadas

No KNN e no Boosting, as etapas de preparação foram ajustadas apenas no treino de cada dobra, dentro de um Pipeline, para evitar vazamento de informação.

VARIÁVEIS

Variáveis originais (1/3)

Coluna	O que representa e valores	Distribuição nos elegíveis	Por que está aqui
Q006	Renda mensal da família. A nenhuma, B até R$ 1.320, ... P até R$ 26.400, Q acima de R$ 26.400	B = 29,3% C = 15,6% Q = 1,6%	Condição econômica
Q001	Escolaridade do pai/responsável. A nunca estudou ... G pós-graduação, H não sei	E = 30,1% H = 9,5%	Contexto educacional da família
Q002	Escolaridade da mãe/responsável. Igual a Q001	—	Contexto educacional da família
TP_ESCOLA	Tipo de escola do ensino médio. 1 não respondeu, 2 pública, 3 privada	1 = 61,0% 2 = 31,0% 3 = 8,0%	Diferença entre rede pública e privada

VARIÁVEIS

Variáveis originais (2/3)

Coluna	O que representa e valores	Distribuição nos elegíveis	Por que está aqui
TP_ST_CONCLUSAO	Situação do ensino médio. 1 já concluiu, 2 conclui em 2023, 3 conclui depois de 2023, 4 não cursa	1 = 41,2% 2 = 39,0% 3 = 19,4%	Momento escolar do participante
TP_FAIXA_ETARIA	Faixa etária. 1 menos de 17; 2–10 = 17 a 25 anos; 11–19 = faixas de 5 anos; 20 mais de 70	—	Idade e experiência
Q005	Pessoas que moram na casa, contando o participante. 1 a 20	mediana 4	Usada no cálculo da renda por pessoa
Q024	Computadores em casa. A nenhum, B 1, C 2, D 3, E 4 ou mais	A = 48,4% B = 35,9%	Acesso a recursos de estudo

VARIÁVEIS

Variáveis originais (3/3)

Coluna	O que representa e valores	Distribuição nos elegíveis	Por que está aqui
Q025	Internet em casa. A não, B sim	B = 91,6%	Acesso a recursos de estudo
IN_TREINEIRO	Fez a prova só para treinar. 0 não, 1 sim	1 = 19,4%	O perfil e a motivação de quem treina são diferentes
SG_UF_PROVA	Estado onde fez a prova. 27 siglas	todas as 27 presentes	Diferenças regionais. Não é necessariamente o estado onde mora
TP_LINGUA	Língua estrangeira escolhida. 0 inglês, 1 espanhol	0 = 57,5%	Parte da prova de LC depende dela. Não mede fluência

VARIÁVEIS

Variáveis criadas

RENDA_PER_CAPITA_APROX

Cálculo. Ponto médio da faixa de Q006 ÷ Q005. Ex.: B (0 a 1.320 → 660) com 2 moradores = 330

Valores. Reais por pessoa; mediana R$ 550. Vazio em 44.132 linhas (todas com Q006 = Q)

Por quê. R$ 3.000 para 2 pessoas é diferente de R$ 3.000 para 8 pessoas. A faixa Q não tem teto, então não existe ponto médio; foi deixada vazia em vez de inventar um valor

ESCOLARIDADE_MAX_RESP

Cálculo. A maior escolaridade entre Q001 e Q002, só quando os dois são conhecidos (A–G)

Valores. A–G ou INDETERMINADA (10,4%)

Por quê. Um único responsável com faculdade já muda o ambiente da casa. Se algum dos dois é H (“não sei”), não dá para afirmar qual é o máximo

PERFIL_ACESSO_DIGITAL

Cálculo. Combinação de Q024 (tem computador?) e Q025 (tem internet?)

Valores.
COMPUTADOR_E_INTERNET 51,1%
SOMENTE_INTERNET 40,5%
SEM_COMPUTADOR_SEM_INTERNET 7,9%
SOMENTE_COMPUTADOR 0,5%

Por quê. Junta as duas informações num perfil só. “Somente internet” geralmente significa acesso só pelo celular

TRATAMENTO DOS DADOS

Separação e decisões

Só quem tem nota

Sem nota não existe o valor a ser previsto, e não dá para treinar nem avaliar.

Nota zero mantida

Zero é uma nota obtida, não ausência de nota.

Treineiros mantidos

Eles também fazem a prova, e excluí-los mudaria a população estudada.

Sem remoção por informação faltante

Ninguém foi removido por falta de informação nas features.

TRATAMENTO DOS DADOS

Qualidade dos dados

Ausentes

Nenhum nas 12 features originais. O único vazio é RENDA_PER_CAPITA_APROX (44.132 linhas, sempre Q006 = Q).

Códigos inválidos

Nenhum, todos os valores estão no dicionário do Inep.

Inscrições duplicadas

Nenhuma.

Valores preenchidos artificialmente

Nenhum. Não houve imputação, padronização nem codificação.

MODELOS · KAYLANY

Árvore de Decisão e Stacking

Árvore de Decisão

Modelo de regressão baseado em árvore de decisão.

- Profundidade máxima de 15
- Mínimo de 20 amostras por folha

Stacking

Ensemble que combina dois modelos-base: Árvore de Decisão e Regressão Ridge.

- Combinação final das previsões também com regressão Ridge
- Validação cruzada interna com três divisões (cv=3)
- Configuração otimizada para reduzir o tempo de treinamento, mantendo a base completa

RESULTADOS PRELIMINARES · KAYLANY

Árvore de Decisão vs. Stacking

Métrica	Árvore de Decisão	Stacking
MAE	50,8338	50,9053
RMSE	65,9927	66,0497
R^2	0,2325	0,2312
Tempo de treinamento	304,62 s	266,77 s

Avaliação no mesmo conjunto de teste. Em negrito, o melhor valor de cada métrica.

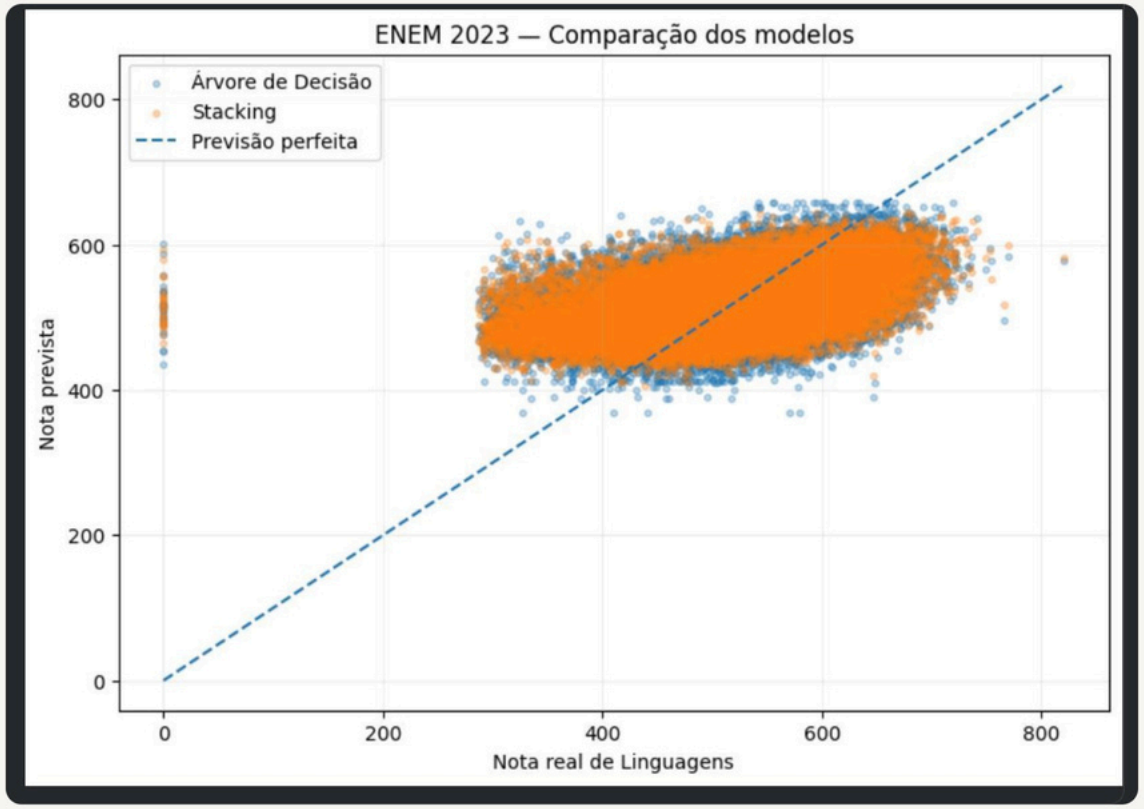
Árvore de Decisão. Ligeiramente melhor nas três métricas: menor MAE, menor RMSE e maior R^2.

Stacking. Menor tempo de treinamento, mas sem melhoria significativa nas previsões.

Os dois modelos tiveram desempenhos próximos nesta avaliação inicial.

ANÁLISE GRÁFICA · KAYLANY

Notas reais vs. notas previstas



Comparação entre as notas reais de Linguagens e as notas previstas pelos dois modelos.

O gráfico mostra a distribuição das previsões em relação à linha de previsão perfeita.

As previsões se concentram em uma faixa intermediária de notas, o que indica dificuldade dos modelos em estimar valores muito baixos ou muito altos.

MODELOS · JOÃO GUILHERME

KNN e Boosting

KNN (K-Nearest Neighbors)

- 50 vizinhos, ponderação pelo inverso da distância (weights="distance") e busca por kd-tree
- Imputação (mediana nas numéricas, valor mais frequente nas categóricas), padronização das numéricas e codificação one-hot das categóricas
- PCA incremental em lotes de 20 mil linhas, para preservar 80% da variância: 18 componentes em todas as dobras (cerca de 80,2%)

Boosting (HistGradientBoosting)

- HistGradientBoostingRegressor com taxa de aprendizado de 0,1, no máximo 200 iterações e 31 folhas por árvore
- Variáveis categóricas com codificação ordinal, tratadas como categorias nativas pelo modelo
- Parada antecipada (early stopping) com 10% do treino de cada dobra como validação interna e paciência de 10 iterações

RESULTADOS PRELIMINARES · JOÃO GUILHERME

KNN vs. Boosting

Métrica	KNN	Boosting
MAE	56,39 (±0,03)	50,30 (±0,04)
RMSE	73,40 (±0,03)	65,33 (±0,08)
R^2	0,0544 (±0,0012)	0,2509 (±0,0008)
Treinamento	18,47 s	8,87 s
Predição	93,89 s	2,15 s

Média das 3 dobras, com desvio padrão entre parênteses. MAE e RMSE em pontos da nota. Avaliação inicial, com hiperparâmetros padrão e sem ajuste de busca. Em negrito, o melhor valor.

O Boosting foi melhor nas três métricas.

MAE. Cerca de 6 pontos abaixo do KNN (redução de aproximadamente 11%).

RMSE. Cerca de 8 pontos abaixo (redução de aproximadamente 11%).

R^2. Explicou cerca de 25% da variação das notas, contra cerca de 5% do KNN.

Tempo. Treinou em cerca de metade do tempo e previu cerca de 44 vezes mais rápido.

RESULTADOS PRELIMINARES · JOÃO GUILHERME

Leitura dos resultados

Estabilidade

Os desvios padrão entre as dobras foram muito pequenos (RMSE abaixo de 0,1 ponto nos dois modelos): a diferença é estável e não decorre da forma como os dados foram divididos.

Referência da média

O desvio padrão das notas é de cerca de 75,5 pontos, próximo ao erro de um modelo que sempre prevê a média. O RMSE do KNN (73,40) fica pouco abaixo disso, o que mostra que ele aprendeu pouco dos dados.

Poder explicativo

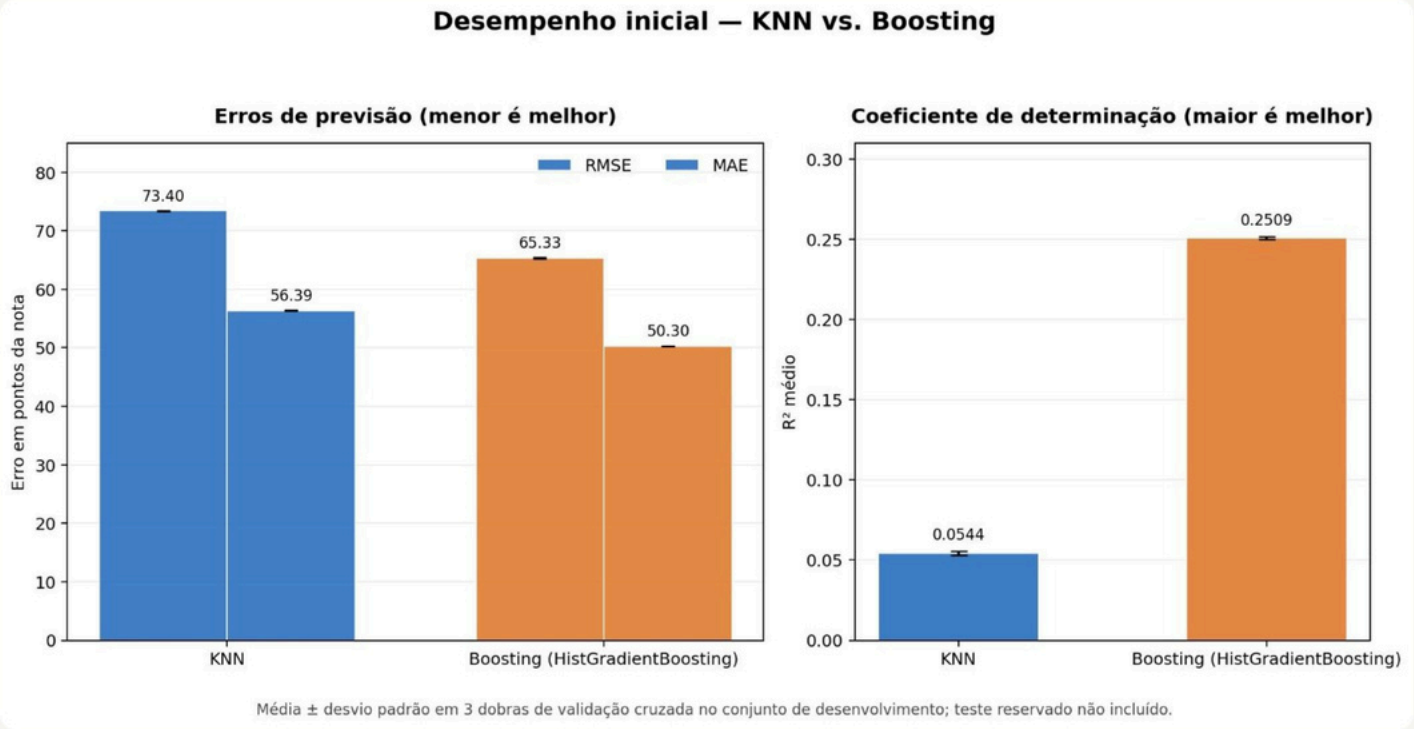
O Boosting reduziu o erro de forma mais clara, mas o R^2 de 0,25 indica que a maior parte da variação das notas não é explicada apenas pelo perfil socioeconômico e escolar disponível nas variáveis.

Possível explicação para o KNN

As variáveis são quase todas categóricas, o que torna a distância euclidiana menos informativa, e o PCA descartou cerca de 20% da variância.

ANÁLISE GRÁFICA · JOÃO GUILHERME

Desempenho inicial: KNN vs. Boosting



RMSE e MAE (em pontos da nota) no painel esquerdo e R^2 no direito, com média e desvio padrão das 3 dobras.

As barras do Boosting ficam abaixo das do KNN nos dois erros e acima no R^2. As barras de erro são praticamente imperceptíveis, o que confirma a estabilidade entre as dobras.

O gráfico de notas reais contra previstas e a análise dos resíduos serão produzidos após a definição da solução final, com o conjunto de teste reservado.