UNIVERSIDADE DE FORTALEZA

CURSO DE CIÊNCIA DA COMPUTAÇÃO

APLICAÇÃO DE TÉCNICAS DE APRENDIZADO DE MÁQUINA NA PREDIÇÃO DAS NOTAS DE LINGUAGENS DO ENEM 2023

Kaylany Vitória Andrade Sousa
Maria Bianca Holanda de Castro
João Victor Lopes de Carvalho
João Guilherme Ribeiro Lobo

Variável-alvo: `NU_NOTA_LC`
Repositório: `https://github.com/BiancaHCastro/LinguagemEnem`

Fortaleza – Ceará
2026

Resumo

Este trabalho investiga a aplicação de técnicas de aprendizado de máquina na estimativa da nota de Linguagens, Códigos e suas Tecnologias do Exame Nacional do Ensino Médio (ENEM) de 2023. Para isso, são utilizados os microdados disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), considerando informações socioeconômicas, demográficas e escolares dos participantes. A variável-alvo é `NU_NOTA_LC`. O desenvolvimento envolveu o tratamento e a engenharia de atributos, a comparação de modelos de regressão, a avaliação de seleção de features, PCA e balanceamento, e a otimização dos três regressores de menor erro. Os 2.822.643 registros com nota observada foram divididos em desenvolvimento (80%) e teste reservado (20%). O conjunto C07, com 23 atributos, foi escolhido pela relação entre desempenho e número de variáveis. Após a busca de hiperparâmetros, o *HistGradientBoostingRegressor* HGB-6 alcançou RMSE de 64,43 ± 0,08 na validação cruzada e, no teste final de 564.529 participantes, RMSE de 64,32, MAE de 49,42 e R^2 de 0,271. O modelo supera o baseline pela média, mas apresenta erros elevados nas notas extremas e explica apenas parte da variação do desempenho. Random Forest e LinearSVR também foram avaliados como referências no estudo, sem superar o modelo selecionado.

Palavras-chave: aprendizado de máquina; ENEM; regressão; previsão de notas; ciência de dados.

1 Introdução e contextualização

A análise de dados tem se tornado uma ferramenta importante para compreender fenômenos educacionais e identificar padrões presentes em grandes conjuntos de informações. No contexto da educação brasileira, o Exame Nacional do Ensino Médio (ENEM) representa uma das principais avaliações educacionais do país, reunindo dados sobre o desempenho dos participantes e informações relacionadas às suas características sociais, econômicas, demográficas e escolares. A disponibilidade desses dados permite investigar relações entre o perfil dos participantes e os resultados obtidos nas diferentes áreas do conhecimento (INEP, 2024).

Com o crescimento do volume de dados disponíveis, técnicas de aprendizado de máquina passaram a ser utilizadas para identificar padrões e construir modelos capazes de realizar estimativas a partir de variáveis de entrada. Na tarefa de regressão, o objetivo consiste em prever um valor numérico com base nas características observadas. Nesse cenário, os microdados do ENEM oferecem uma oportunidade para investigar até que ponto informações sobre o contexto dos participantes podem contribuir para estimar suas notas.

Este trabalho tem como foco a previsão da nota da prova de Linguagens, Códigos e suas Tecnologias do ENEM 2023, representada pela variável `NU_NOTA_LC`. A proposta

consiste em utilizar informações socioeconômicas, demográficas e escolares dos participantes para treinar diferentes modelos de regressão, comparar seus resultados e identificar aquele que apresenta o desempenho preditivo mais adequado. A investigação considera não apenas a métrica de desempenho, mas também os limites das informações utilizadas e a capacidade dos modelos de representar diferentes faixas de nota.

Para alcançar esse propósito, o projeto foi organizado em etapas que envolvem o processamento dos microdados, a análise e seleção de atributos, a criação de novas features e o treinamento de modelos de aprendizado de máquina. Após a comparação inicial, os modelos mais promissores foram selecionados para experimentos de otimização, incluindo busca de hiperparâmetros e técnicas de redução de dimensionalidade e tratamento da distribuição do alvo, conforme os requisitos do projeto.

1.1 Justificativa

A escolha do tema justifica-se pela relevância dos dados do ENEM para estudos relacionados à educação brasileira e pela possibilidade de aplicar técnicas de ciência de dados a um problema real de regressão. A previsão de notas a partir de características dos participantes permite investigar quais informações apresentam associação com o desempenho e avaliar os limites de modelos que não utilizam diretamente respostas, gabaritos ou resultados das demais áreas da prova.

Além disso, o volume expressivo dos microdados exige cuidados específicos de preparação, processamento e avaliação. A utilização de diferentes algoritmos possibilita comparar abordagens com comportamentos distintos, enquanto a engenharia e a seleção de features permitem investigar se representações mais informativas dos dados contribuem para a qualidade das estimativas. Dessa forma, o projeto articula conceitos de preparação de dados, modelagem preditiva, validação e interpretação de resultados.

1.2 Objetivos

1.2.1 Objetivo geral

Desenvolver e comparar modelos de aprendizado de máquina capazes de estimar a nota de Linguagens, Códigos e suas Tecnologias do ENEM 2023, utilizando características socioeconômicas, demográficas e escolares dos participantes, com o propósito de identificar uma configuração com desempenho preditivo adequado e analisar suas limitações.

1.2.2 Objetivos específicos

Os objetivos específicos consistiram em caracterizar a base de dados e a distribuição da variável-alvo, tratar as informações necessárias à modelagem, selecionar atributos relevantes e construir novas features. Também compreenderam o treinamento e a comparação de modelos de regressão, a avaliação dos resultados por métricas apropriadas, a otimização dos modelos selecionados e a análise dos erros de previsão.

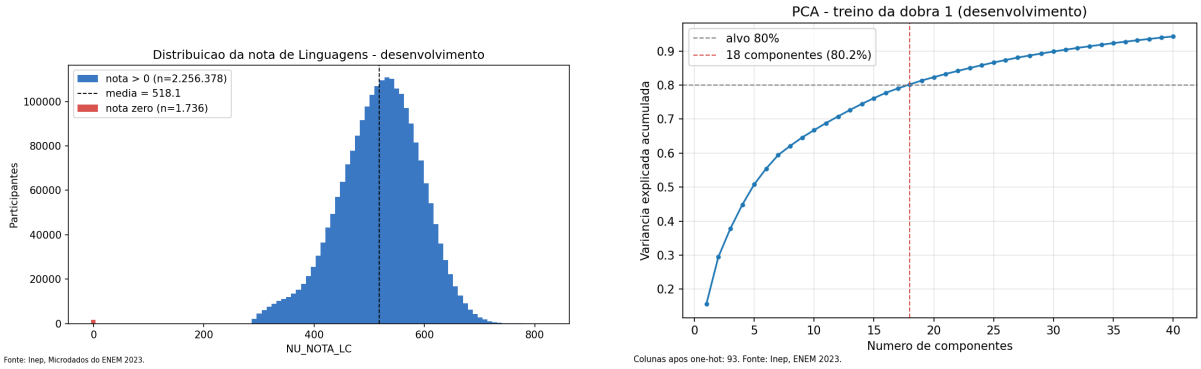
A investigação foi conduzida para identificar um modelo preditivo consistente sem utilizar informações da correção da prova como preditores. A comparação final incluiu um conjunto de teste reservado para avaliar a generalização a participantes não vistos da mesma edição; as relações observadas não permitem estabelecer causalidade.

2 Metodologia

2.1 Dados, participantes elegíveis e protocolo

A fonte de dados utilizada é o arquivo nacional de microdados do ENEM 2023, disponibilizado pelo Inep (INEP, 2024). O protocolo de avaliação também observa os requisitos do Projeto 2 da disciplina (UNIFOR, 2026). A base original contém 3.933.955 registros e 76 colunas. Para a tarefa supervisionada, são considerados os 2.822.643 participantes que possuem valor observado na variável-alvo `NU_NOTA_LC`. Registros sem nota observada não são utilizados no treinamento ou na avaliação supervisionada. Notas iguais a zero são mantidas por representarem resultados observados, e os participantes classificados como treineiros também são preservados. No conjunto elegível foram identificadas 2.169 notas zero: 1.736 no desenvolvimento e 433 no teste.

A separação aleatória destinou 80% dos participantes ao desenvolvimento (2.258.114) e 20% ao teste reservado (564.529), com `random_state=42`. No desenvolvimento, foi utilizada validação cruzada *KFold* com três dobras, embaralhamento e a mesma semente. As comparações e buscas utilizaram as mesmas dobras. A seleção de features, modelos e hiperparâmetros do protocolo C07 ocorreu somente no desenvolvimento; o conjunto de teste não orientou nenhuma dessas escolhas. A avaliação final do HGB-6 foi realizada após sua seleção, em comparação ao baseline e à regressão linear sem regularização. Os resultados de Random Forest e LinearSVR no teste são apresentados como referências adicionais do mesmo estudo, sem interferir na escolha da solução final.



(a) Distribuição da nota de Linguagens no desenvolvimento, incluindo 1.736 notas zero.

(b) 24 componentes; aproximadamente 80% da variância.

Figura 1: Distribuição da variável-alvo e diagnóstico da redução por PCA.

Fonte: Elaboração própria a partir dos microdados do ENEM 2023 (desenvolvimento) e da análise exploratória do C13 (PCA).

2.2 Preparação e engenharia de features

A preparação envolveu a análise das variáveis selecionadas, a verificação de valores ausentes, códigos inválidos e inscrições duplicadas, além da avaliação da adequação dos atributos ao problema. A representação inicial documentou doze features originais. Não foram identificados códigos inválidos nem inscrições duplicadas, e não houve remoção de participantes por ausência de informação nas features originais. A ausência registrada na feature `RENDA_PER_CAPITA_APROX` está associada às observações da faixa de renda sem limite superior definido.

A engenharia de atributos começou com três variáveis derivadas: renda per capita aproximada, calculada a partir do ponto médio da faixa de renda e da quantidade de moradores; escolaridade máxima conhecida entre os responsáveis; e perfil de acesso digital, que combina as informações sobre computador e internet no domicílio. A engenharia foi ampliada durante a triagem, com dezoito features novas candidatas e diferentes conjuntos experimentais. O conjunto C07, escolhido para a comparação consolidada, contém 23 features (14 originais do Inep e nove criadas pela equipe). Entre as criadas estão `ANOS_DESDE_CONCLUSAO`, `ATRASO_ESCOLAR`, `TIPO_ESCOLA_DETALHADO`, `RENDA_PER_CAPITA_APROX`, `ESCOLARIDADE_MAX_RESP` e `PERFIL_ACESSO_DIGITAL`. A língua estrangeira escolhida (`TP_LINGUA`) é uma opção de prova, não uma medida de proficiência. Essa composição representa uma etapa posterior à curadoria inicial de doze variáveis.

As notas das outras áreas, respostas, gabaritos, presença e informações produzidas pela correção não foram utilizadas como atributos preditores, para evitar vazamento de informação. As transformações que aprendem parâmetros a partir dos dados foram ajustadas dentro dos *pipelines* e exclusivamente na parcela de treino de cada dobra. No HistGradientBoosting, categorias foram tratadas nativamente, enquanto as ausências numéricas foram mantidas, pois o estimador dispõe de tratamento próprio para esses valores (Pedregosa et al., 2011; Scikit-learn Developers, 2026).

2.3 Modelos e métodos

A comparação inicial consolidada no C07 apresenta oito regressores e o baseline da média: regressão linear sem regularização (OLS), Ridge, Árvore de Decisão (Breiman et al., 1984); K-Nearest Neighbors (KNN); Bagging; Pasting; HistGradientBoosting; e Stacking. LinearSVR e Random Forest também foram avaliados no estudo e são retomados como referências comparativas na seção de resultados. Assim como os regressores da comparação consolidada, essas avaliações consideraram 23 atributos do conjunto C07; seus resultados são apresentados como referências complementares, sem constituir experimentos independentes. A regressão Ridge acrescenta uma penalização L2 aos coeficientes, enquanto a regressão linear OLS minimiza a soma dos quadrados dos resíduos (Hoerl e Kennard, 1970). O KNN estima a nota a partir dos vizinhos mais próximos no espaço transformado,

sendo sensível à representação e à escala das variáveis (Cover e Hart, 1967). O LinearSVR utiliza uma função de perda insensível a uma margem e uma fronteira linear, opção escolhida diante do custo de kernels densos na base com milhões de registros (Cortes e Vapnik, 1995).

Bagging combina preditores treinados em amostras com reposição; Pasting utiliza subamostras sem reposição. Ambos agregam previsões de estimadores individuais (Breiman, 1996). Random Forest também combina árvores, mas introduz aleatoriedade na seleção de atributos durante as divisões (Breiman, 2001). O Boosting constrói modelos sequencialmente, ajustando novas árvores aos erros residuais das etapas anteriores (Friedman, 2001). O Stacking combina previsões de modelos-base por meio de um estimador final; para reduzir vazamento, o combinador foi treinado com previsões fora da dobra (Wolpert, 1992).

2.4 Seleção, PCA e balanceamento

Foram montados 16 conjuntos principais de features com hipóteses distintas, além de oito experimentos de ablação por blocos. A escolha das variáveis buscou preservar informações de família, renda, escolaridade, língua e localização sem incluir notas ou respostas do exame. A triagem exploratória utilizou 300 mil participantes do desenvolvimento, três dobras e três regressores (Linear, Árvore e HistGradientBoosting). O conjunto C11, com 54 colunas, obteve o menor RMSE nessa triagem, mas C07 ficou em segundo lugar nos três modelos e utilizou menos da metade das variáveis, permitindo executar a comparação na base elegível completa. A seleção automática por *SelectKBest* foi testada no C12. A redução de dimensionalidade por Análise de Componentes Principais (PCA) foi avaliada no C13, com codificação e padronização anteriores à redução; 24 componentes substituíram as features e preservaram aproximadamente 80% da variância do treino. No C14, o PCA foi aplicado apenas ao bloco de bens, mantendo os demais atributos. O PCA foi testado em regressão linear, Árvore de Decisão e HistGradientBoosting. A técnica representa as variáveis por combinações lineares ortogonais que concentram variância (Jolliffe e Cadima, 2016).

Também foram realizados testes de balanceamento das faixas da variável-alvo, motivados pela baixa frequência das notas extremas. Como o problema é de regressão, as notas permaneceram numéricas, e os ajustes foram restritos aos treinos, sem reequilibrar validação ou teste. Na etapa exploratória de balanceamento, observou-se aumento de 0,5 a 15 pontos no RMSE. O registro experimental não permite identificar com precisão o procedimento de reamostragem ou ponderação, de modo que os resultados são apresentados sem atribuição a uma técnica específica. As faixas foram mantidas para a avaliação dos erros, sem alterar a distribuição dos conjuntos reservados.

2.5 Métricas, busca e curva de aprendizado

A avaliação utiliza o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE) e o coeficiente de determinação (R^2). MAE representa a média das diferenças absolutas entre os valores observados e previstos. RMSE penaliza de maneira mais intensa erros de maior magnitude e foi adotado como métrica principal. R^2 indica quanto da variabilidade da variável-alvo é explicada pelo modelo em relação à referência baseada na média. Os tempos de execução também foram registrados.

Após a comparação inicial, os três melhores regressores distintos (HistGradientBoosting, Bagging e Pasting) foram submetidos a buscas com dez configurações válidas cada. O HistGradientBoosting foi ajustado por *GridSearchCV*, com estratégias fundamentadas em hipóteses sobre taxa de aprendizado, número e tamanho das árvores, regularização e sorteio de features. Bagging e Pasting utilizaram *RandomizedSearchCV*. A escolha considerou o RMSE médio nas mesmas três dobras; o teste não participou das buscas.

A curva de aprendizado do modelo final foi calculada com cinco tamanhos de treino (10%, 25%, 50%, 75% e 100% do treino de cada dobra), mantendo a validação fixa. Para cada tamanho, o *pipeline* foi ajustado novamente, e a média e o desvio padrão do RMSE foram calculados entre as três dobras.

3 Resultados

3.1 Comparação inicial dos modelos

A Tabela 1 apresenta os resultados consolidados da validação cruzada no desenvolvimento. As métricas são médias entre três dobras; o desvio padrão é apresentado para o RMSE. Os tempos correspondem ao tempo total registrado para cada avaliação inicial e dependem do ambiente de execução, não equivalendo a tempos de inferência isolados.

Tabela 1: Comparação inicial na validação cruzada do desenvolvimento (C07).

Modelo	RMSE (média ± DP)	MAE (média ± DP)	R^2 (média ± DP)	Tempo (s)
HistGradientBoosting	64,50 ± 0,09	49,61 ± 0,05	0,2697 ± 0,0007	50,98
Bagging	65,26 ± 0,08	50,24 ± 0,04	0,2525 ± 0,0005	117,17
Pasting	65,27 ± 0,09	50,25 ± 0,04	0,2522 ± 0,0007	107,74
Stacking	65,30 ± 0,10	50,31 ± 0,05	0,2517 ± 0,0008	141,94
Regressão linear (OLS)	65,54 ± 0,11	50,54 ± 0,06	0,2462 ± 0,0009	39,48
Ridge	65,54 ± 0,11	50,54 ± 0,06	0,2462 ± 0,0009	31,60
KNN	70,86 ± 0,05	54,51 ± 0,04	0,1188 ± 0,0008	763,78
Baseline (média)	75,48 ± 0,08	59,35 ± 0,08	≈ 0	30,35
Árvore de Decisão	92,34 ± 0,03	71,16 ± 0,08	$-0,4965 \pm 0,0043$	74,95

Fonte: Elaboração própria com base nos registros de validação cruzada da equipe, utilizando as três dobras do desenvolvimento.

A análise também contemplou LinearSVR e Random Forest, cujos resultados são mantidos como referências dentro do mesmo estudo. Nos registros apresentados nas Figuras 3, o LinearSVR obteve RMSE de 65,40 na validação cruzada e 65,32 no teste (R^2 de 0,2480); o Random Forest registrou, respectivamente, 65,24 e 65,07 (R^2 de 0,2538 no

teste). Ambos superaram o baseline do teste (RMSE 75,33), porém não o HGB-6 (RMSE 64,32). Esses dois regressores também utilizaram os 23 atributos do C07. Suas métricas são apresentadas como referências complementares, sem alterar a classificação da Tabela 1, cujos resultados provêm do CSV consolidado da comparação inicial. A Árvore de Decisão também possui uma configuração anterior com profundidade máxima de 15 e mínimo de 20 observações por folha; a tabela contém a configuração registrada no CSV consolidado, sem restrição de profundidade e com mínimo de uma observação por folha.

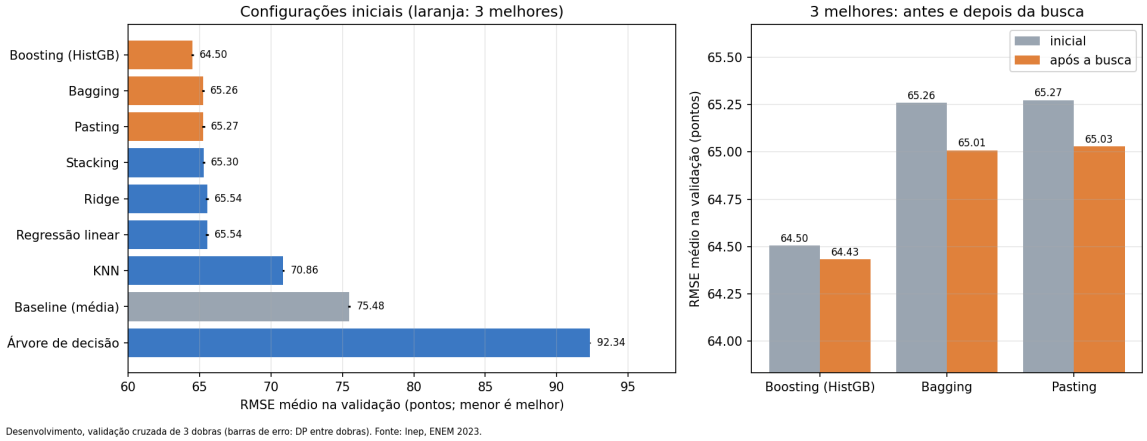
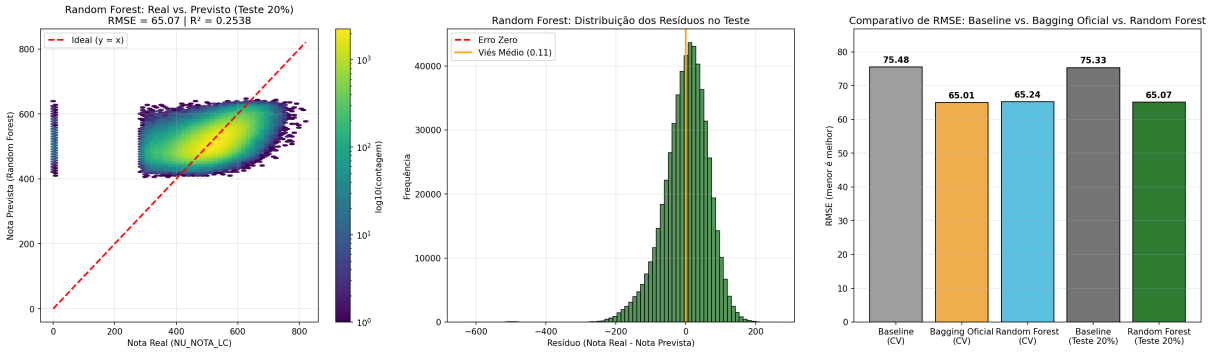


Figura 2: RMSE médio dos modelos na validação cruzada inicial e dos três melhores após a busca de hiperparâmetros.

Fonte: Elaboração própria a partir dos resultados de validação cruzada registrados pela equipe. As barras de erro representam o desvio padrão entre as dobras.



(a) Random Forest: observado versus previsto, distribuição dos resíduos e RMSE comparativo.

Figura 3: Resultados de Random Forest, comparado ao bagging referências na análise dos modelos.

Fonte: Gráficos produzidos pela equipe com os resultados de Random Forest do conjunto C07.

3.2 Comparação dos conjuntos de features

A Tabela 2 resume conjuntos representativos da triagem exploratória. O C11 completo apresentou o menor RMSE do HistGradientBoosting (64,10), mas utilizou 54 colunas. O C07, com 23 colunas, ficou em segundo lugar nos três modelos testados e apresentou menor custo de representação para executar os demais algoritmos na base elegível completa. A

ablação por blocos indicou maior contribuição da situação escolar (a retirada elevou o RMSE em 0,9 ponto) e da língua estrangeira (a retirada elevou em 0,6 ponto).

Tabela 2: Resultados de conjuntos de features na triagem exploratória (RMSE, amostra de 300 mil participantes).

Conjunto	Colunas	Linear	Árvore	Boosting
C01 — originais	12	66,52	66,77	65,62
C07 — trajetória escolar	23	65,68	66,31	64,87
C11 — completo	54	64,87	66,28	64,10
C12 — SelectKBest	20	67,17	67,59	66,73
C13 — PCA global	24	66,44	67,93	65,94
C14 — PCA dos bens	31	65,95	66,97	65,16

Fonte: Resumo dos conjuntos de features da equipe. A triagem utilizou as mesmas três dobras em uma amostra do desenvolvimento; não corresponde à validação final na base completa.

3.3 Busca de hiperparâmetros e modelo final

Os três modelos selecionados apresentaram ganhos pequenos após a busca. O HistGradientBoosting passou de RMSE 64,50 para 64,43; o Bagging, de 65,26 para 65,01; e o Pasting, de 65,27 para 65,03. Foram avaliadas dez configurações por modelo, totalizando trinta configurações. O sorteio de features em cada divisão foi a característica com efeito mais consistente nas melhores estratégias do Boosting.

Tabela 3: Resultados dos três regressores antes e depois da busca de hiperparâmetros.

Modelo	Método	Inicial	Após busca	Ganho RMSE	Tempo busca (s)
HistGradientBoosting	GridSearchCV	64,50	64,43	0,07	1.432,82
Bagging	RandomizedSearchCV	65,26	65,01	0,25	657,39
Pasting	RandomizedSearchCV	65,27	65,03	0,24	1.953,97

Fonte: Resultados das buscas de hiperparâmetros da equipe, com dez configurações válidas por regressor.

A configuração final HGB-6 utiliza taxa de aprendizado 0,02, até 4.000 iterações (1.145 árvores utilizadas após parada antecipada), no máximo 127 folhas por árvore, mínimo de 300 observações por folha, regularização L2 igual a 1,0 e sorteio de 50% das features em cada divisão. A parada antecipada utilizou 10% do treino de cada dobra e paciência de 50 iterações.

Tabela 4: Avaliação final no conjunto de teste reservado (564.529 participantes).

Modelo	RMSE	MAE	R^2	Tempo total (s)
Baseline (média)	75,33	59,19	0,000	13,58
Regressão linear OLS	65,46	50,45	0,245	18,43
HistGradientBoosting HGB-6	**64,32**	**49,42**	**0,271**	134,63

Fonte: Experimentos de teste final da equipe. Os três modelos foram avaliados nos mesmos participantes, após ajuste em todo o conjunto de desenvolvimento.

3.4 Aprofundamento do modelo final

Para avaliar se o erro nas notas pouco frequentes poderia ser reduzido sem prejudicar a previsão global, cinco variações da configuração HGB-6 foram comparadas usando as mesmas três dobras. A retirada das notas zero ocorreu apenas na parcela de treino de cada dobra, preservando as observações na validação. As outras variações testaram perda

absoluta, transformação por quantis do alvo, restrições monotônicas e redução do tamanho das árvores.

Tabela 5: Aprofundamento do HGB-6 no desenvolvimento: erros gerais e em notas extremas.

Estratégia	RMSE geral	MAE geral	RMSE (0–400)	RMSE ($\geq$ 700)
HGB-6: referência	64,43	49,55	134,3	136,8
Sem zeros no treino	64,43	49,51	134,6	136,2
Perda absoluta	64,72	**49,34**	139,5	**130,9**
Alvo por quantis	64,53	49,37	137,7	133,9
Restrições monotônicas	64,49	49,59	134,3	136,5
Árvores com 31 folhas	64,44	49,55	134,3	137,0

Fonte: Elaboração própria; cinco variações avaliadas por validação cruzada no desenvolvimento, com erros de faixa calculados nas respectivas validações.

Nenhuma variação conseguiu reduzir simultaneamente os erros dos dois extremos e melhorar o RMSE geral. A perda absoluta diminuiu o MAE e o erro nas notas mais altas, mas elevou o RMSE geral e o erro nas notas mais baixas. Uma alternativa computacionalmente menos custosa foi o HGB-4, com RMSE 64,44 e cerca de metade do tempo de ajuste por dobra; o HGB-6 foi mantido por apresentar a menor média de RMSE, embora a diferença entre ambos seja muito inferior ao desvio entre as dobras.

3.5 Curva de aprendizado e análise dos erros

A curva de aprendizado indica redução da diferença entre treino e validação conforme aumenta o número de participantes utilizados. Com 10% do treino de cada dobra, a diferença entre os RMSE foi de aproximadamente 2,2 pontos; com 100%, caiu para 0,6 ponto. A validação melhorou de 64,81 para 64,44, sugerindo estabilização e ausência de indício de sobreajuste forte no HGB-6.

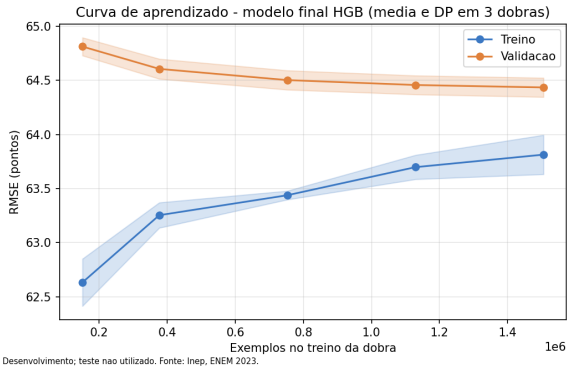
A Tabela 6 registra todos os cinco tamanhos de treino, com médias e desvios padrão das três dobras. A validação foi mantida fixa em cada dobra, o que torna os pontos comparáveis.

Tabela 6: Curva de aprendizado do HGB-6 (RMSE, média $\pm$ DP entre três dobras).

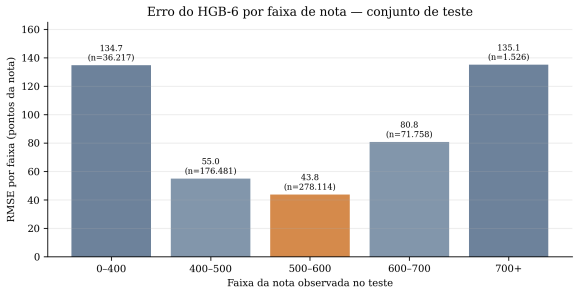
Treino por dobra	RMSE treino	RMSE validação	Diferença
150 mil (10%)	62,63 $\pm$ 0,22	64,81 $\pm$ 0,08	2,2
376 mil (25%)	63,25 $\pm$ 0,12	64,61 $\pm$ 0,09	1,4
753 mil (50%)	63,44 $\pm$ 0,04	64,50 $\pm$ 0,09	1,1
1,13 milhão (75%)	63,70 $\pm$ 0,11	64,46 $\pm$ 0,09	0,8
1,51 milhão (100%)	63,81 $\pm$ 0,18	64,44 $\pm$ 0,09	0,6

Fonte: Elaboração própria; percentuais calculados sobre o subconjunto de treinamento de cada dobra do desenvolvimento.

No teste, o RMSE foi menor na faixa de notas observadas entre 500 e 600 (43,8; 278.114 participantes) e maior nas faixas extremas. Para notas entre 0 e 400, excluídas as notas iguais a zero, o RMSE foi 134,7 (36.217 participantes), com superestimação média de 127,3 pontos; para notas acima de 700, o RMSE foi 135,1 (1.526 participantes), com subestimação média de 130,9 pontos. As 433 notas zero do teste tiveram RMSE de 512,8.



(a) Curva de aprendizado; média e DP entre dobras.



(b) RMSE por faixa no teste.

Figura 4: Diagnóstico do HGB-6: evolução do erro com o tamanho do treino e desempenho por faixa de nota.

Fonte: Curva de aprendizado calculada no desenvolvimento; erros por faixa calculados no teste reservado.

As previsões ficaram entre 382 e 663 pontos, com desvio padrão de 39, enquanto o desvio padrão das notas observadas foi 75.

Tabela 7: Erros do HGB-6 por faixa da nota observada no teste.

Faixa	Participantes	RMSE	Viés (observada − prevista)
Zero	433	512,8	−510, 9
0–400 (exceto zero)	36.217	134,7	−127, 3
400–500	176.481	55,0	−38, 7
500–600	278.114	43,8	+22, 9
600–700	71.758	80,8	+72, 2
700+	1.526	135,1	+130, 9

Fonte: Arquivo consolidado de erros por faixa de nota no teste. O viés é calculado como nota observada menos nota prevista.

Por tipo de escola, os RMSE reportados foram 61,7 na rede privada, 64,0 na pública e 64,8 para participantes que não responderam. Por renda familiar, os extremos documentados foram 60,1 na faixa N e 65,6 na faixa B. Entre as unidades da federação, os menores RMSE ocorreram em Santa Catarina (60,7) e Rio Grande do Sul (61,1); os maiores, no Ceará (67,8), Piauí (67,3) e Roraima (67,0). Os tamanhos dos grupos de escola foram conferidos no arquivo consolidado de erros do teste: 45.007 participantes na rede privada, 174.578 na pública e 344.944 sem resposta à pergunta de tipo de escola. Juntos, esses grupos correspondem aos 564.529 registros do teste, conforme a Tabela 8.

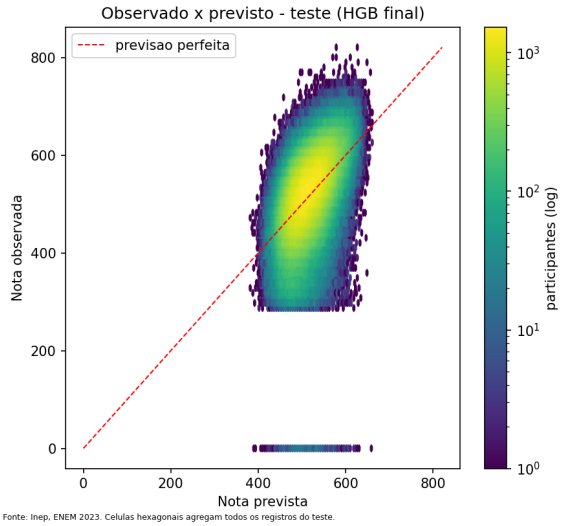
Tabela 8: Desempenho por grupo no teste.

Variável	Grupo	Participantes (n)	RMSE
Tipo de escola	Privada	45.007	61,7
Tipo de escola	Pública	174.578	64,0
Tipo de escola	Não respondeu	344.944	64,8

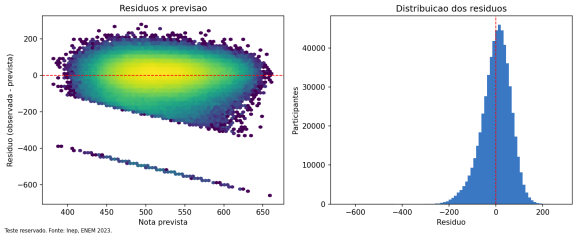
Fonte: Elaboração própria, calculado sobre os microdados do ENEM 2023.

3.6 Relevância preditiva dos atributos

A importância por permutação foi estimada em uma amostra de 100 mil participantes da validação da primeira dobra, com cinco repetições por atributo e sem utilizar o conjunto



(a) Dispersão e linha de previsão perfeita ($y = x$).



(b) Resíduos (nota observada menos nota prevista).

Figura 5: Diagnóstico das previsões do HGB-6 no conjunto de teste.

Fonte: Elaboração própria a partir das previsões do modelo final sobre os microdados do ENEM 2023.

de teste. A medida representa o aumento do RMSE quando os valores de uma feature são embaralhados, desorganizando sua associação com o alvo.

Tabela 9: Principais atributos do HGB-6: aumento do RMSE sob permutação.

Feature	ΔRMSE (pontos)
`ANOS_DESDE_CONCLUSAO`	2,40
`TP_LINGUA`	1,82
`TP_FAIXA_ETARIA`	1,76
`RENDA_PER_CAPITA_APROX`	1,15
`SG_UF_PROVA`	1,06
`TIPO_ESCOLA_DETALHADO`	0,63

Fonte: Elaboração própria; permutação na validação da primeira dobra do desenvolvimento, em 100 mil observações e cinco repetições.

A análise indica a contribuição preditiva de atributos ligados à trajetória escolar, à língua escolhida, à idade, à renda e ao local da prova. Como vários atributos são correlacionados, a permutação isolada pode subestimar o efeito de blocos informacionais; esses valores não representam efeitos causais nem justificam inferir proficiência a partir da opção de língua estrangeira.

4 Discussão

O HistGradientBoosting foi o melhor modelo entre os resultados consolidados. No teste reservado, alcançou RMSE 64,32, MAE 49,42 e R^2 0,271, reduzindo o RMSE em aproximadamente 11 pontos em relação ao baseline pela média e em 1,14 ponto em relação à regressão linear OLS. A proximidade entre a validação cruzada (RMSE 64,43) e o teste (64,32) indica que o desempenho observado no desenvolvimento se manteve nos participantes reservados.

Os ganhos obtidos pela otimização foram pequenos: 0,07 ponto no HistGradient-

Boosting, 0,25 no Bagging e 0,24 no Pasting. O sorteio de features em cada divisão foi a característica com efeito mais consistente nas melhores estratégias do Boosting. Bagging e Pasting ficaram próximos após o ajuste, indicando que, nessas configurações, o uso de amostras com ou sem reposição não foi determinante.

A seleção de features apresentou um compromisso entre desempenho e custo. Embora o conjunto completo C11 tenha obtido o menor RMSE na triagem, o C07 foi escolhido por ficar em segundo lugar nos três modelos testados e utilizar menos da metade das colunas. A seleção automática C12 e as representações por PCA C13 e C14 apresentaram erros maiores que C11. O PCA global utilizou 24 componentes para preservar aproximadamente 80% da variância, mas não melhorou o desempenho dos regressores avaliados. Os testes exploratórios de balanceamento por faixa aumentaram o RMSE entre 0,5 e 15 pontos. A remoção das notas zero apenas do treino de cada dobra não alterou o RMSE; as demais variações do HGB-6 também não reduziram os erros extremos sem penalizar o desempenho geral.

A curva de aprendizado mostra que a diferença entre treino e validação cai de 2,2 para 0,6 ponto entre 10% e 100% do treino da dobra. A validação melhora apenas 0,37 ponto, indicando estabilização e ausência de sobreajuste forte no modelo final. Em contrapartida, os erros altos e próximos, combinados ao R^2 de 0,271, apontam um limite de informação: as features descrevem o perfil socioeconômico, escolar e demográfico, mas não contemplam diretamente hábitos de estudo, preparação, domínio dos conteúdos ou condições do participante no dia da prova.

A análise por faixa evidencia concentração das previsões em uma faixa intermediária: o modelo superestima notas baixas e subestima notas altas, sendo mais preciso entre 500 e 600 pontos. As diferenças de RMSE por tipo de escola, renda e unidade da federação devem ser lidas considerando o número de observações por grupo. Para tipo de escola, a Tabela 8 apresenta os tamanhos efetivamente observados; o grupo sem resposta é o mais numeroso. A amplitude reduzida das previsões (382 a 663 pontos), comparada à dispersão da variável-alvo, é coerente com os vieses observados nas faixas extremas.

A avaliação permite discutir a generalização para participantes não vistos da edição de 2023, mas não demonstra desempenho em outras edições, escolas ou municípios inéditos. As associações identificadas não devem ser interpretadas como relações causais nem como medida da capacidade individual de um participante.

5 Conclusão

Este trabalho investigou a aplicação de técnicas de aprendizado de máquina na previsão da nota de Linguagens, Códigos e suas Tecnologias do ENEM 2023, utilizando informações socioeconômicas, demográficas e escolares dos participantes. Oito regressores compuseram a comparação consolidada do C07, além do baseline, e LinearSVR e Random Forest integraram o mesmo estudo como referências adicionais, também com os 23 atributos

selecionados. Também foram realizadas análises de conjuntos de features, PCA, seleção automática, balanceamento e otimização de hiperparâmetros.

A configuração HGB-6 do HistGradientBoosting apresentou o melhor resultado entre os modelos consolidados, com RMSE 64,32, MAE 49,42 e R^2 0,271 no teste reservado. A comparação com o baseline e com a regressão linear mostrou que o perfil disponível contribui para a estimativa da nota, mas explica apenas parte de sua variação. A curva de aprendizado e as comparações de complexidade sugerem que o limite observado está mais relacionado à informação disponível nas features do que apenas à necessidade de aumentar a complexidade do modelo. Assim, os resultados identificam padrões úteis, mas reforçam que previsões baseadas exclusivamente no perfil dos participantes devem ser interpretadas com cautela.

O estudo distinguiu a triagem exploratória de atributos, a validação cruzada utilizada para escolha e ajuste dos modelos e a avaliação final em participantes reservados. A generalização para outras edições do exame requer estudos adicionais; os resultados também não autorizam interpretações causais das relações entre o perfil dos participantes e suas notas.

Referências

BREIMAN, Leo et al. **Classification and Regression Trees**. Boca Raton: Chapman and Hall, 1984. ISBN 9780412048418.

BREIMAN, Leo. Bagging Predictors. *Machine Learning*, v. 24, p. 123–140, 1996. DOI: 10.1007/BF00058655.

BREIMAN, Leo. Random Forests. *Machine Learning*, v. 45, p. 5–32, 2001. DOI: 10.1023/A:1010933404324.

CORTES, Corinna; VAPNIK, Vladimir. Support-Vector Networks. *Machine Learning*, v. 20, n. 3, p. 273–297, 1995. DOI: 10.1007/BF00994018.

COVER, Thomas M.; HART, Peter E. Nearest Neighbor Pattern Classification. *IEEE Transactions on Information Theory*, v. 13, n. 1, p. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964.

FRIEDMAN, Jerome H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. DOI: 10.1214/aos/1013203451.

HOERL, Arthur E.; KENNARD, Robert W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, v. 12, n. 1, p. 55–67, 1970. DOI: 10.1080/00401706.1970.10488634.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA. **Microdados do Enem 2023**. Brasília, DF: Inep, 2024. Disponível em: `https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem`. Acesso em: 20 out. 2026.

JOLLIFFE, Ian T.; CADIMA, Jorge. Principal Component Analysis: A Review and Recent Developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, v. 374, n. 2065, p. 20150202, 2016. DOI: 10.1098/rsta.2015.0202.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: `https://jmlr.org/papers/v12/pedregosa11a.html`.

SCIKIT-LEARN DEVELOPERS. **Scikit-learn 1.9.1 User Guide**. 2026. Disponível em: `https://scikit-learn.org/stable/user_guide.html`. Acesso em: 28 out. 2026.

UNIVERSIDADE DE FORTALEZA. **Projeto 2: Aprendizado de Máquina com Dados do ENEM: requisitos, entregas e avaliação da disciplina de Ciência de Dados**. Fortaleza: Universidade de Fortaleza, 2026. Material didático da Unidade II.

WOLPERT, David H. Stacked Generalization. *Neural Networks*, v. 5, n. 2, p. 241–259, 1992. DOI: 10.1016/S0893-6080(05)80023-1.