UNIFOR | CIÊNCIA DE DADOS | PROJETO 2

Previsão da nota de Linguagens do ENEM

Algoritmos de aprendizado de máquina aplicado aos microdados do ENEM 2023

Equipe:
João Vitor Lopes
João Guilherme
Kaylany Vitoria
Maria Bianca Holnada

O que podemos estimar a partir do perfil do participante?

Uma investigação preditiva, não uma explicação causal do desempenho individual.

PERGUNTA DE PESQUISA

Em que medida informações socioeconômicas, demográficas e escolares ajudam a estimar a nota de Linguagens do ENEM?

OBJETIVO GERAL

Comparar algoritmos de regressão e estratégias de preparação para identificar a solução com melhor desempenho preditivo e compreender suas limitações.

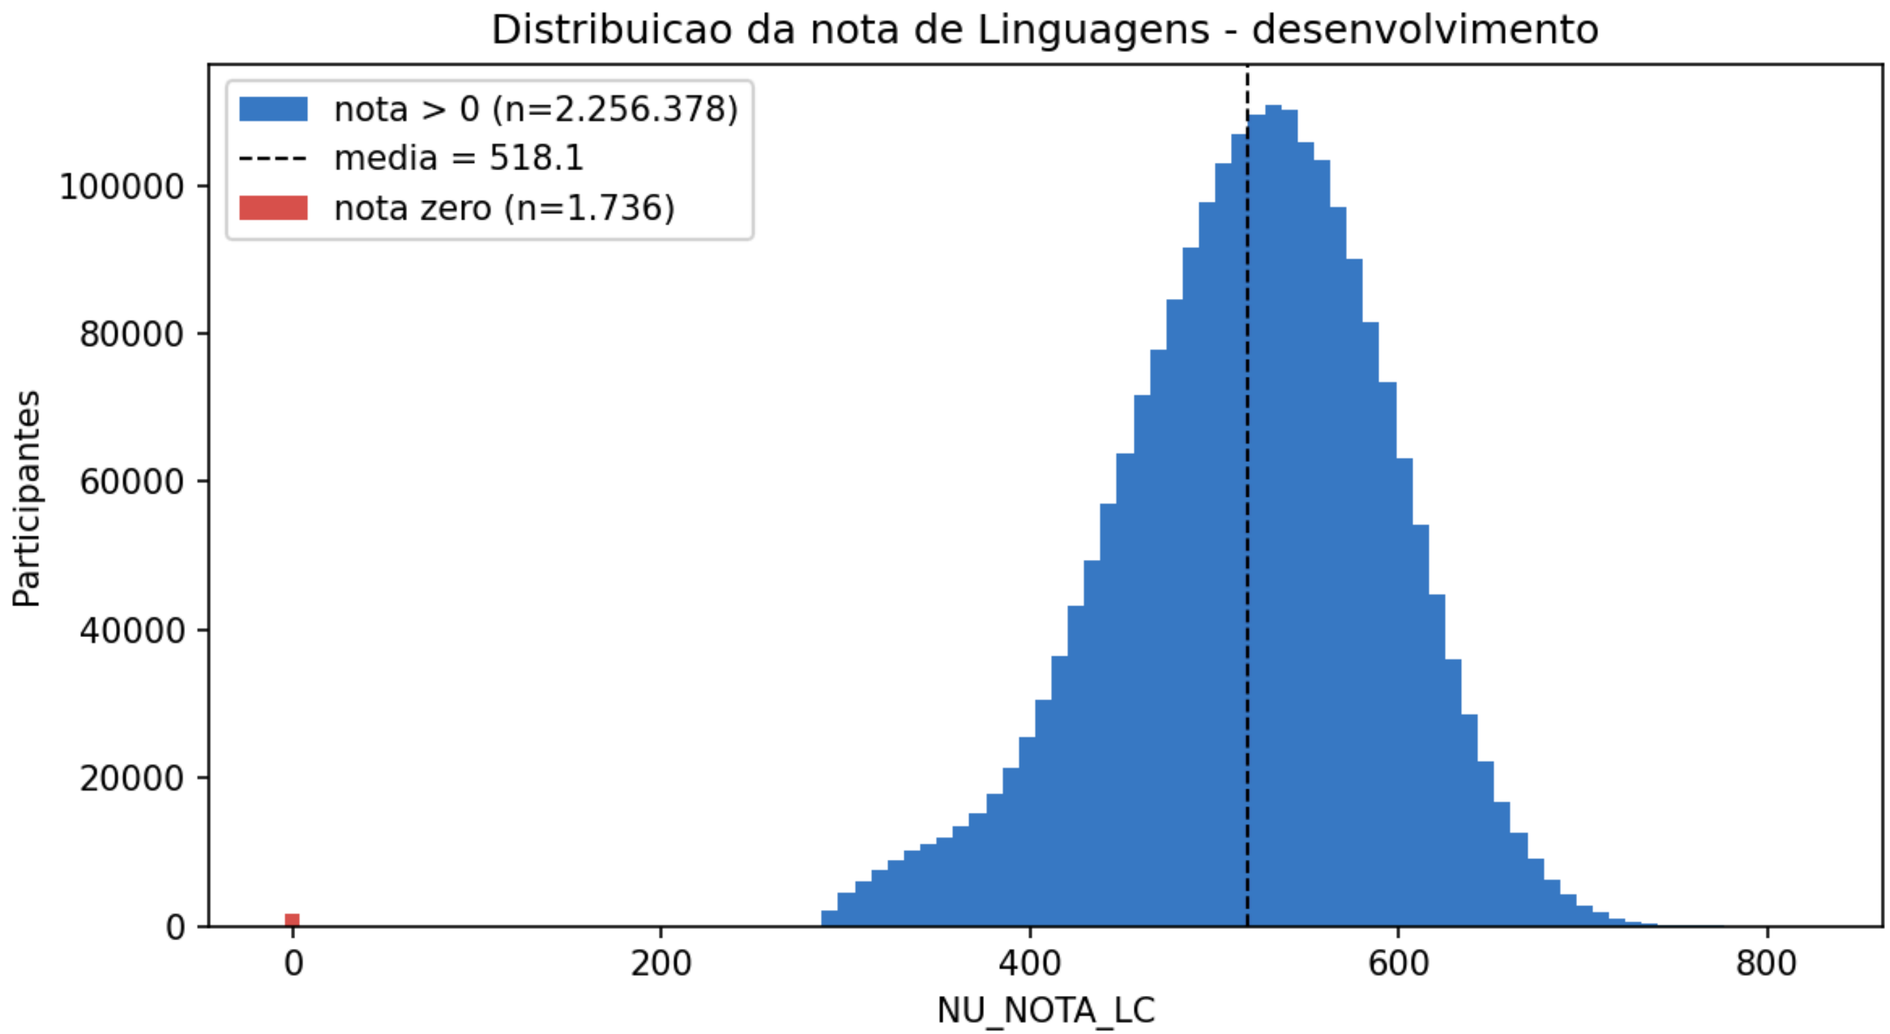
ESCOPO

A variável prevista é numérica: NU_NOTA_LC. O projeto compara modelos com protocolo de avaliação consistente e reserva um conjunto de teste para a avaliação final.

INTERPRETAÇÃO

Associações entre perfil e nota não demonstram causalidade nem determinam a capacidade individual de um participante.

Distribuição da Nota - Resultado final



Fonte: Inep, Microdados do ENEM 2023.

Uma base nacional com milhões de participantes

Microdados do ENEM 2023 · Inep · unidade de observação: um participante por linha.

REGISTROS NA BASE COMPLETA	COM NOTA-ALVO OBSERVADA	DESENVOLVIMENTO · 80%	TESTE RESERVADO · 20%
3.933.955	2.822.643	2.258.114	564.529

PARTICIONAMENTO DA BASE ELEGÍVEL



2.258.114 participantes

564.529 participantes

Semente aleatória: 42

CRITÉRIO DE ELEGIBILIDADE

Somente participantes com NU_NOTA_LC observada entram no treinamento e na avaliação.

Notas zero são mantidas; ausência de nota não é convertida em zero.

Pipeline de 16 diferentes conjuntos testados

Triagem exploratória: 300 mil participantes do desenvolvimento, 3 dobras; RMSE do HistGradientBoosting.

CONJUNTO	COMPOSIÇÃO / HIPÓTESE	COLUNAS	RMSE HGB
C07 · TRAJETÓRIA ESCOLAR	Família + rede, atraso e tempo desde conclusão	22	64,87
C11 · COMPLETO	União dos blocos permitidos; teto de informação	54	64,10
C04 · FAMÍLIA AMPLIADA	C02 + Ocupação do pai e da mãe, Ocupação máxima dos pais, Capital cultural	20	65,36
C09 · DEMOGRÁFICO	C04 + Raça, Sexo Estado Civil e Nacionalidade	24	65,01
C05 · BENS BRUTOS	C04 + as 17 perguntas de bens da casa	37	64,97
C10 · INTERAÇÕES	C04 + Renda × Espanhol, Renda × Escolaridade dos pais e Acesso digital × Escolaridade dos pais.	23	65,36
C02 · FAMÍLIA E TECNOLOGIA	junta renda, escolaridade dos pais, acesso digital, escola e perfil do participante.	15	65,61

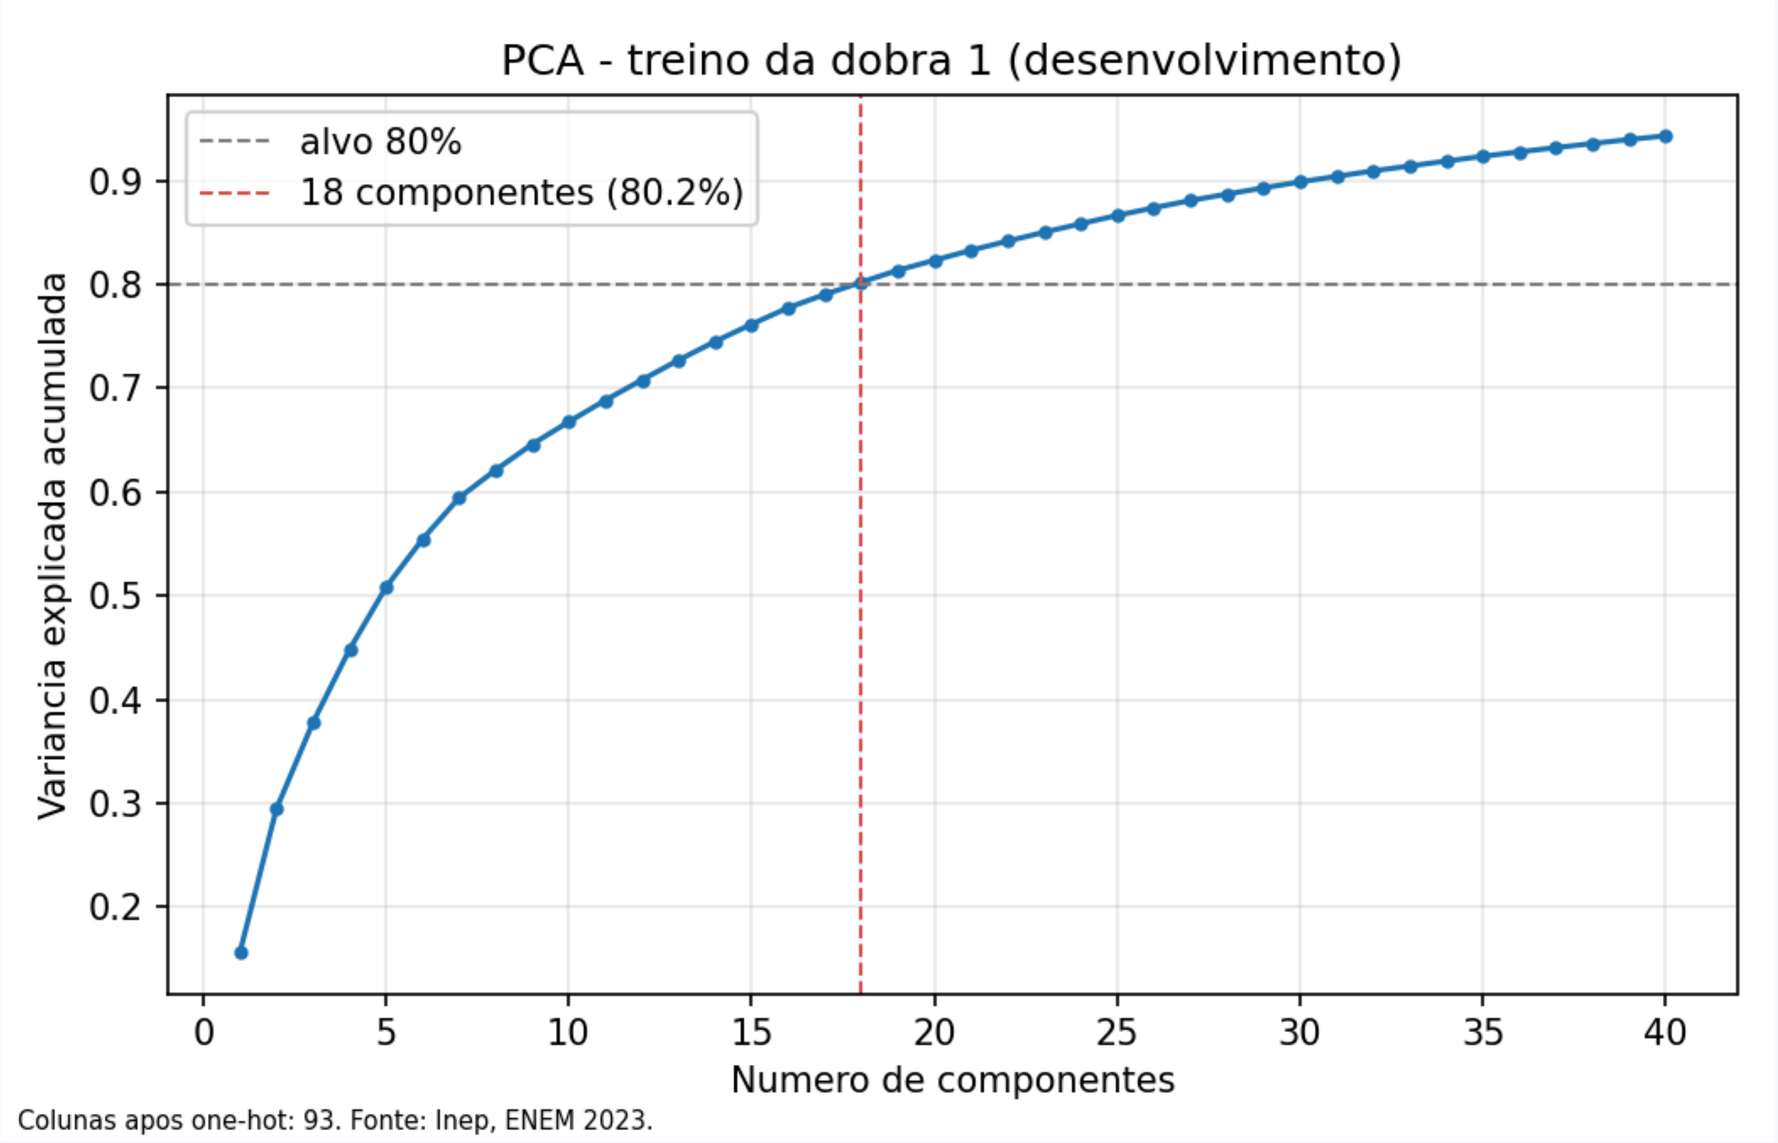
Conjunto final C07: 22 features

14 colunas originais do Inep + 8 criadas pela equipe, em 5 blocos

BLOCO	ORIGINAIS DO INEP (14)	CRIADAS PELA EQUIPE (8)	O QUE CAPTA
Renda 3 features	Renda familiar · Nº de moradores	**Renda per capita**	Poder de compra por pessoa
Família 7 features	Escolaridade do pai e da mãe · Ocupação do pai e da mãe	**Escolaridade máx. · Ocupação máx. · Capital cultural**	Ambiente cultural em casa
Acesso digital 3 features	Computadores · Internet	**Perfil de acesso digital**	Recursos para estudar em casa
Trajetória escolar 6 features	Tipo de escola · Situação do ensino médio · Treineiro	**Rede da escola · Atraso escolar · Anos desde a conclusão**	Federal × estadual, atraso e tempo fora da escola
Perfil 3 features	Faixa etária · UF da prova · Língua estrangeira	—	Idade, região e escolha da língua

Por que o C07: 2º lugar nos 3 modelos da triagem de 16 conjuntos, com 23 colunas contra 54 do 1º lugar

Resultados PCA



Colunas apos one-hot: 93. Fonte: Inep, ENEM 2023.

Comparar com o mesmo protocolo de avaliação

A escolha do modelo deve ocorrer no desenvolvimento; o teste permanece reservado até a decisão final.

01

Separação

80% desenvolvimento
20% teste · random_state=42

02

Validação

KFold · 3 dobras
shuffle=True · seed 42

03

Seleção

RMSE médio como critério
mesmas dobras na comparação

04

Otimização

10 configurações por modelo
Grid/Randomized Search

05

Teste final

Reajuste em 100% do desenvolvimento
avaliação única no teste

TREINAMENTO DE MODELOS

Metodologia para treinar os modelos
Com o objetivo de descobrir qual o modelo mais se adequa a predição das notas,

Os modelos de Machine Learning foram treinados seguindo um mesmo padrão, para que os resultados pudessem ser comparados.

MÉTRICAS

RMSE	principal · penaliza mais erros grandes
MAE	erro absoluto médio em pontos da nota
R^2	fração da variação da nota explicada pelo modelo

VALIDAÇÃO CRUZADA · 3 DOBRAS

Regressão Linear: OLS e Ridge

Ponto de referência para medir quanto relações aditivas conseguem explicar a variação da nota.

CONFIGURAÇÃO E LEITURA

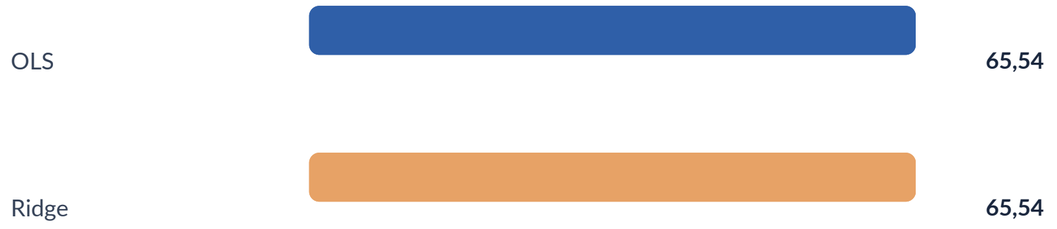
- OLS: regressão linear sem regularização; 23 features de entrada e 77 após codificação.
- Ridge: regularização L2 com alpha = 1,0 para estabilizar coeficientes.
- Pré-processamento com padronização, one-hot e transformação log1p na renda per capita.
- Erro médio parecido em Treino e validação

LEITURA DO EXPERIMENTO

OLS e Ridge apresentaram desempenho praticamente idêntico. A regularização L2 não trouxe ganho mensurável neste volume de dados.

RMSE	MAE	R^2
65,54	50,54	0,246

RMSE médio na validação cruzada



RESULTADO-CHAVE

$R^2 \approx 0,246$: o modelo linear explica cerca de um quarto da variabilidade observada, com raiz do erro quadrático médio (RMSE) de 65,54 pontos

VALIDAÇÃO CRUZADA · 3 DOBRAS

Bagging: agregação de árvores

Treina várias árvores em amostras com reposição e combina suas previsões para reduzir variância.

CONFIGURAÇÃO E LEITURA

- Configuração inicial: 20 árvores, bootstrap=True e folha mínima de 20 amostras.
- Cada árvore recebe amostra com reposição; a previsão é agregada entre estimadores.
- Busca com 10 configurações: mais árvores, fração de linhas e colunas e folha mínima.
- Configuração otimizada registrada: 40 árvores, 75% das linhas e 80% das features.

LEITURA DO EXPERIMENTO

A busca reduziu o RMSE em aproximadamente 0,25 ponto. Mesmo otimizado, o Bagging ficou cerca de 0,58 ponto atrás do Boosting ajustado.

RMSE INICIAL	RMSE TUNING	R^2 TUNING
65,26	65,01	0,258

RMSE · antes e depois do tuning



CONFIGURAÇÃO OTIMIZADA

n_estimators=40 · max_samples=0,75 · max_features=0,80 · min_samples_leaf=20. Resultado medido na validação cruzada do desenvolvimento.

VALIDAÇÃO CRUZADA · 3 DOBRAS

Pasting: amostragem sem reposição

Combina árvores treinadas em subconjuntos sem repetição de linhas dentro de cada amostra.

CONFIGURAÇÃO E LEITURA

- Configuração inicial: 20 árvores; bootstrap=False; max_samples=0,63.
- Diferente do Bagging, cada participante aparece no máximo uma vez em cada subamostra.
- Busca com 10 configurações para número de árvores, linhas, colunas e tamanho mínimo da folha.
- Configuração otimizada registrada: 40 árvores, 63% das linhas e 80% das features.

LEITURA DO EXPERIMENTO

O desempenho ficou praticamente igual ao Bagging. A escolha com ou sem reposição não produziu diferença relevante nesta configuração.

RMSE INICIAL	RMSE TUNING	R^2 TUNING
65,27	65,03	0,258

RMSE · antes e depois do tuning



CONFIGURAÇÃO OTIMIZADA

n_estimators=40 · max_samples=0,63 · max_features=0,80 · min_samples_leaf=20.
Tempo total da busca: cerca de 1.954 s.

VALIDAÇÃO CRUZADA · 3 DOBRAS

Árvore de Decisão: do sobreajuste ao controle

Sem restrições, a árvore memoriza o treino; exigindo 500 participantes por folha, treino e validação se igualam.

CONFIGURAÇÃO E LEITURA

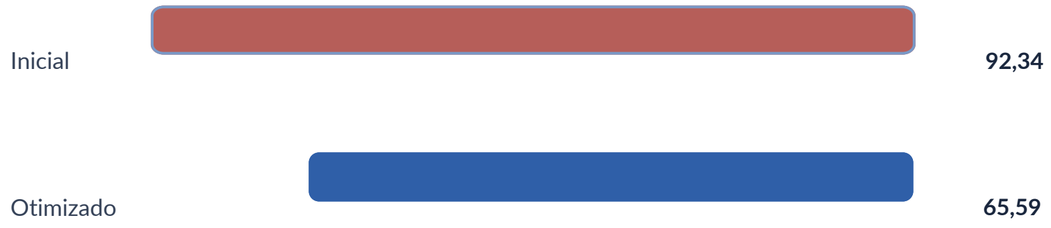
- Inicial: sem limite de crescimento (folha mínima 1); treino 23,32 × validação 92,34.
- Estudo de complexidade: 15 estratégias em GridSearchCV, nas mesmas 3 dobras.
- Escolhida: ARV-F500, min_samples_leaf=500 e sem limite de profundidade.
- Treino 65,25 × validação 65,59: o sobreajuste desaparece.

LEITURA DO EXPERIMENTO

A árvore controlada sai de 92,34 para 65,59 e supera o baseline (75,48). Empata com a regressão linear (65,54), mas segue fora do top 3 (Bagging 65,26).

RMSE INICIAL	RMSE TUNING	R^2 TUNING
92,34	65,59	0,245

RMSE · antes e depois do tuning



ATENÇÃO À VERSÃO

Substitui a versão preliminar (profundidade 15, folha 20). A escolha usou só a validação cruzada: a configuração inicial segue registrada e o teste não foi usado.

VALIDAÇÃO CRUZADA · 3 DOBRAS

Stacking: combinação de modelos

Combina previsões de modelos-base diferentes por meio de um estimador final.

CONFIGURAÇÃO E LEITURA

- Modelos-base: Árvore de Decisão e Ridge.
- Combinador final: regressão Ridge.
- Previsões fora da dobra (OOF) e validação interna com 3 divisões.
- Cada preparação foi ajustada no treino da dobra correspondente.

LEITURA DO EXPERIMENTO

O Stacking ficou muito próximo de Bagging e Pasting, mas não superou o Boosting. Treino e validação próximos sugerem estabilidade no protocolo usado.

RMSE CV	MAE CV	R^2 CV
65,30	50,31	0,252

RMSE · treino e validação



INTERPRETAÇÃO

A combinação de modelos não garante ganho automático: o resultado depende da diversidade e da qualidade das previsões-base.

KNN: previsão por vizinhança

Estima a nota a partir dos participantes mais próximos no espaço das features transformadas.

CONFIGURAÇÃO E LEITURA

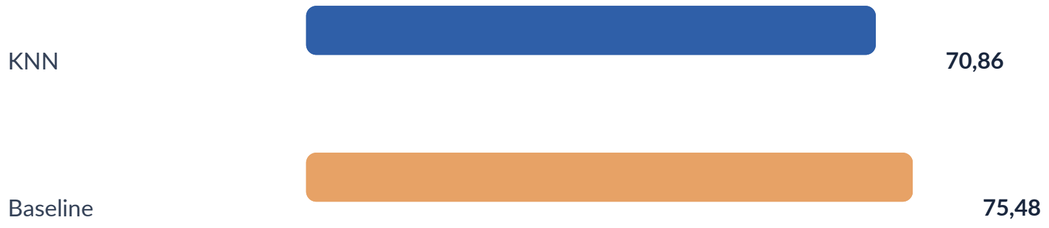
- 50 vizinhos (n_neighbors=50), com pesos pelo inverso da distância.
- KD-tree para busca; distância Minkowski com p=2.
- Pré-processamento com padronização, one-hot e PCA incremental em lotes.
- O CSV consolidado registra 12 componentes PCA

LEITURA DO EXPERIMENTO

O KNN superou a média, mas ficou atrás dos modelos lineares e de ensemble. A distância no espaço transformado pode representar mal perfis com muitas categorias.

RMSE CV	MAE CV	R^2 CV
70,86	54,51	0,119

RMSE · KNN versus baseline



Boosting: aprendizado sequencial

Árvores são adicionadas em sequência; cada etapa busca corrigir erros das etapas anteriores.

CONFIGURAÇÃO E LEITURA

- Implementação: HistGradientBoostingRegressor.
- Configuração inicial: learning_rate=0,1; max_iter=200; max_leaf_nodes=31.
- Categorias nativas; early stopping com 10% do treino da dobra.
- Foi o melhor resultado entre os modelos da comparação inicial consolidada.

LEITURA DO EXPERIMENTO

O Boosting apresentou o menor RMSE inicial (64,50) e um intervalo pequeno entre treino (64,30) e validação (64,50). Foi selecionado para tuning.

RMSE INICIAL	MAE INICIAL	R^2 INICIAL
64,50	49,61	0,270

RMSE · baseline, linear e boosting



PRÓXIMA ETAPA

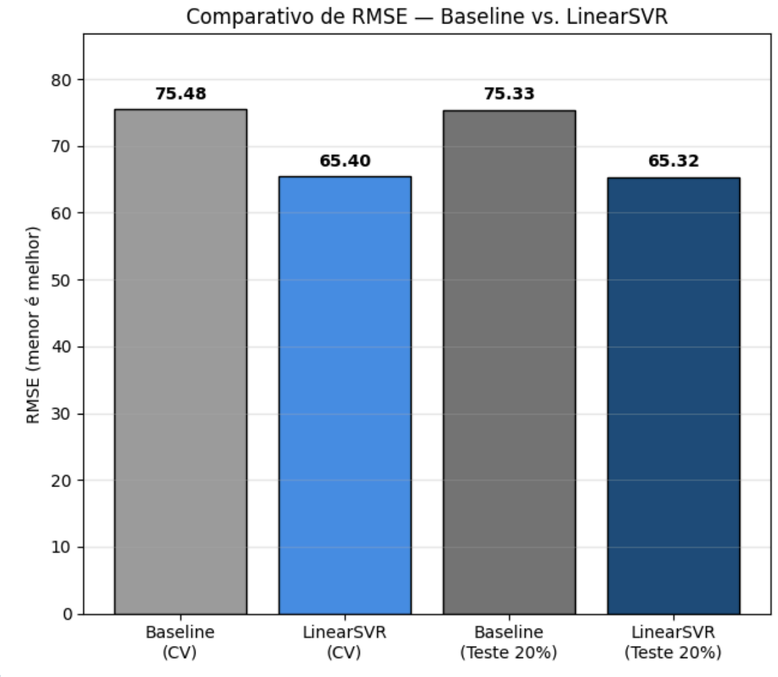
A busca de hiperparâmetros levou à configuração HGB-6: RMSE médio de 64,43 na validação cruzada.

SVM: opção linear para grande escala

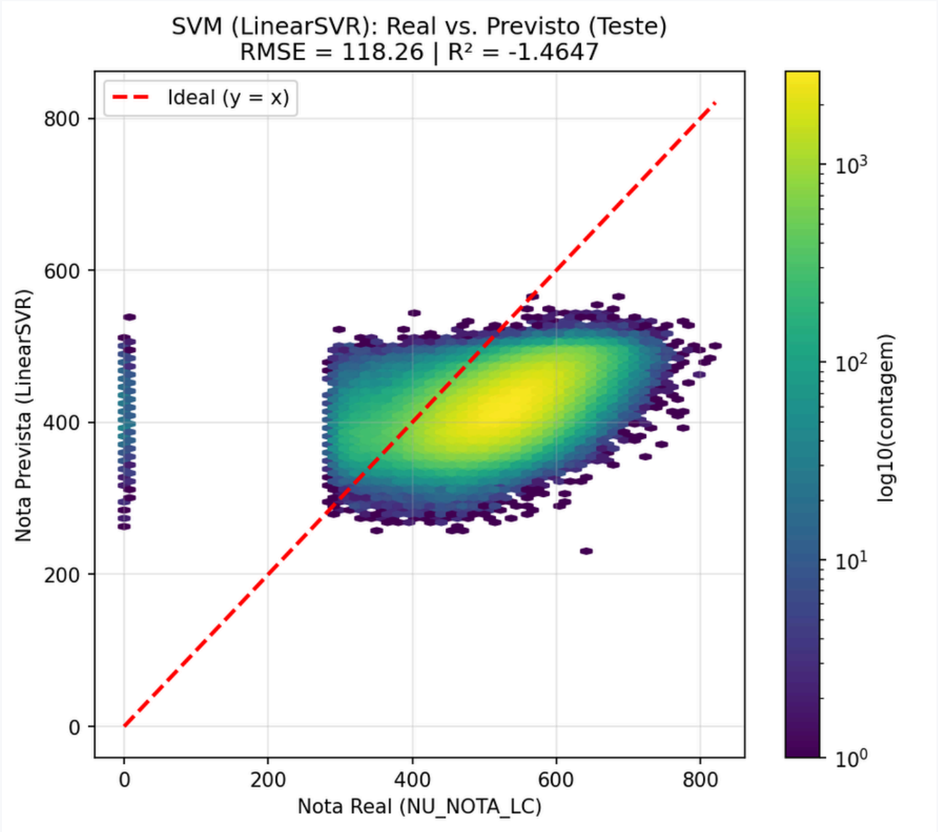
O LinearSVR foi escolhido como alternativa escalável diante do custo de kernels densos em milhões de registros.

CONFIGURAÇÃO E LEITURA

- LinearSVR => Formulação primal (dual=False), regularização C = 1,0 e perda squared_epsilon_insensitive.
- Padronização (StandardScaler) (nº) e One-Hot Encoding (nª)



RMSE CV*	RMSE TESTE*	R² TESTE*
65,40	65,32	0,248

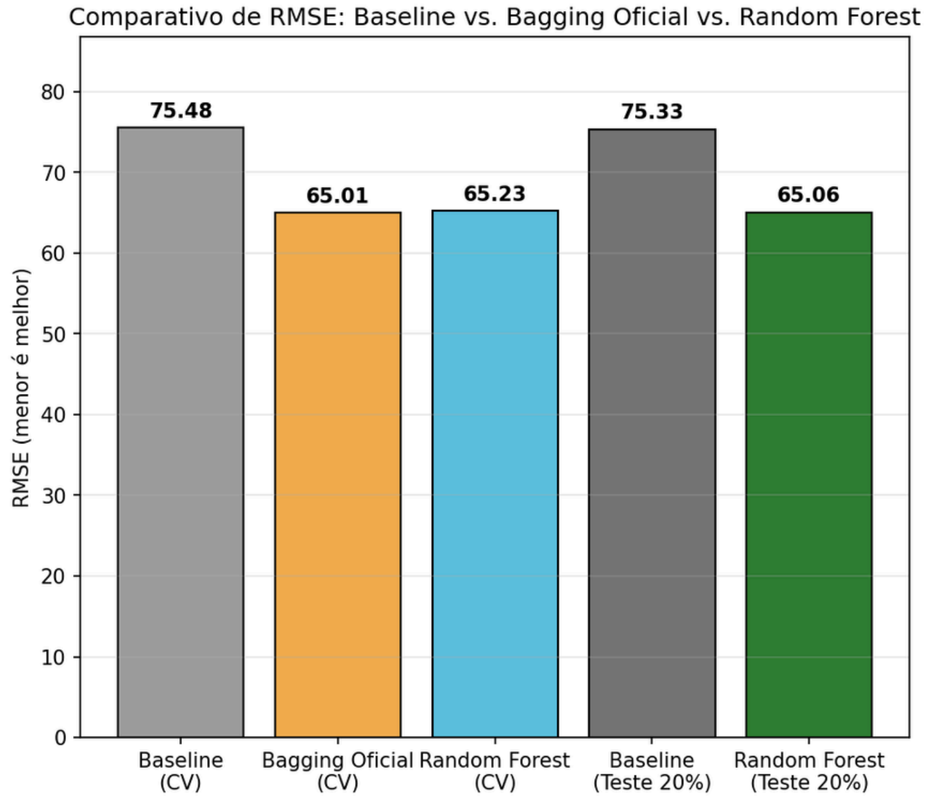


Random Forest: árvores descorrelacionadas

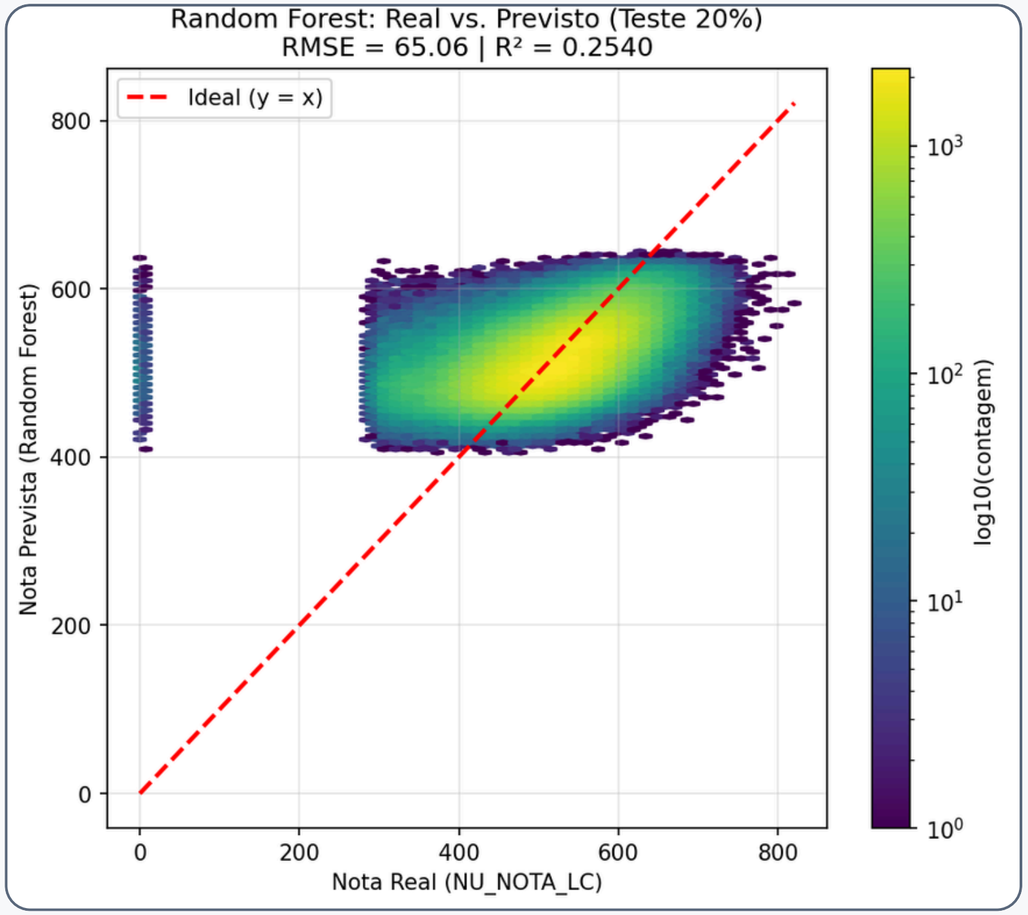
Combina árvores treinadas em amostras com reposição e sorteio de features em cada divisão.

CONFIGURAÇÃO DEFINIDA:

- Árvores de decisão a construir: **40**
- Quantidade de amostras por árvore: **75%**
- Minimo de amostras por folha: **20**



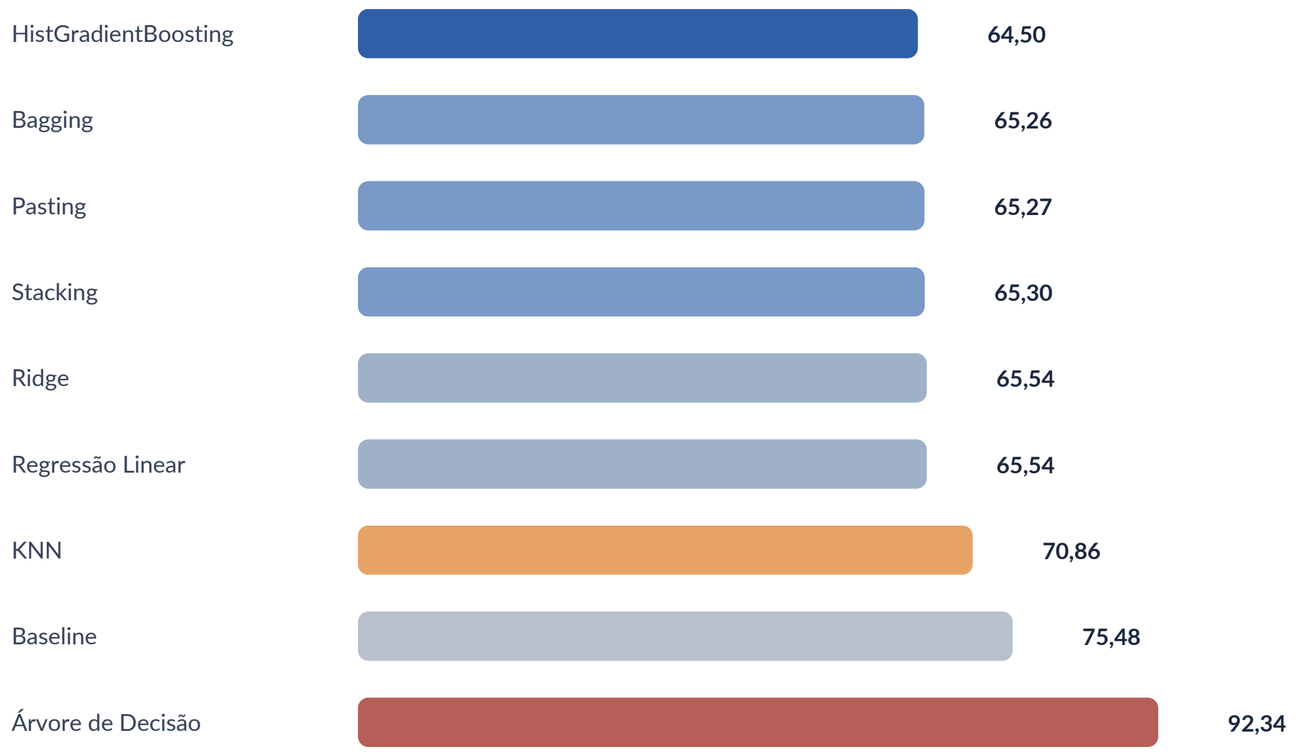
RMSE CV*	RMSE TESTE*	R² TESTE*
65,22	65,06	0,254



O que a comparação inicial mostrou

Ranking por RMSE médio na validação cruzada do conjunto de desenvolvimento · menor é melhor.

RMSE médio · validação cruzada (3 dobras)



TOP 3 PARA TUNING

1 HistGradientBoosting
RMSE 64,50

2 Bagging
RMSE 65,26

3 Pasting
RMSE 65,27

O tuning trouxe ganhos pequenos

Foram avaliadas 10 configurações válidas para cada um dos três modelos selecionados.

MODELO	RMSE INICIAL	RMSE APÓS BUSCA	GANHO	CONFIGURAÇÕES
HistGradientBoosting	64,50	64,43	0,07	10
Bagging	65,26	65,01	0,25	10
Pasting	65,27	65,03	0,24	10

MENOR RMSE APÓS BUSCA

64,43

HistGradientBoosting · HGB-6

RMSE após tuning · comparação dos três



HistGradientBoosting (HGB-6) foi a solução escolhida

Decisão baseada no menor RMSE do desenvolvimento; avaliação final realizada no teste reservado.

RMSE NO TESTE	MAE NO TESTE	R^2 NO TESTE	AMOSTRAS NO TESTE
64,32	49,42	0,271	564.529

RMSE no teste · mesmos participantes



CONFIGURAÇÃO HGB-6

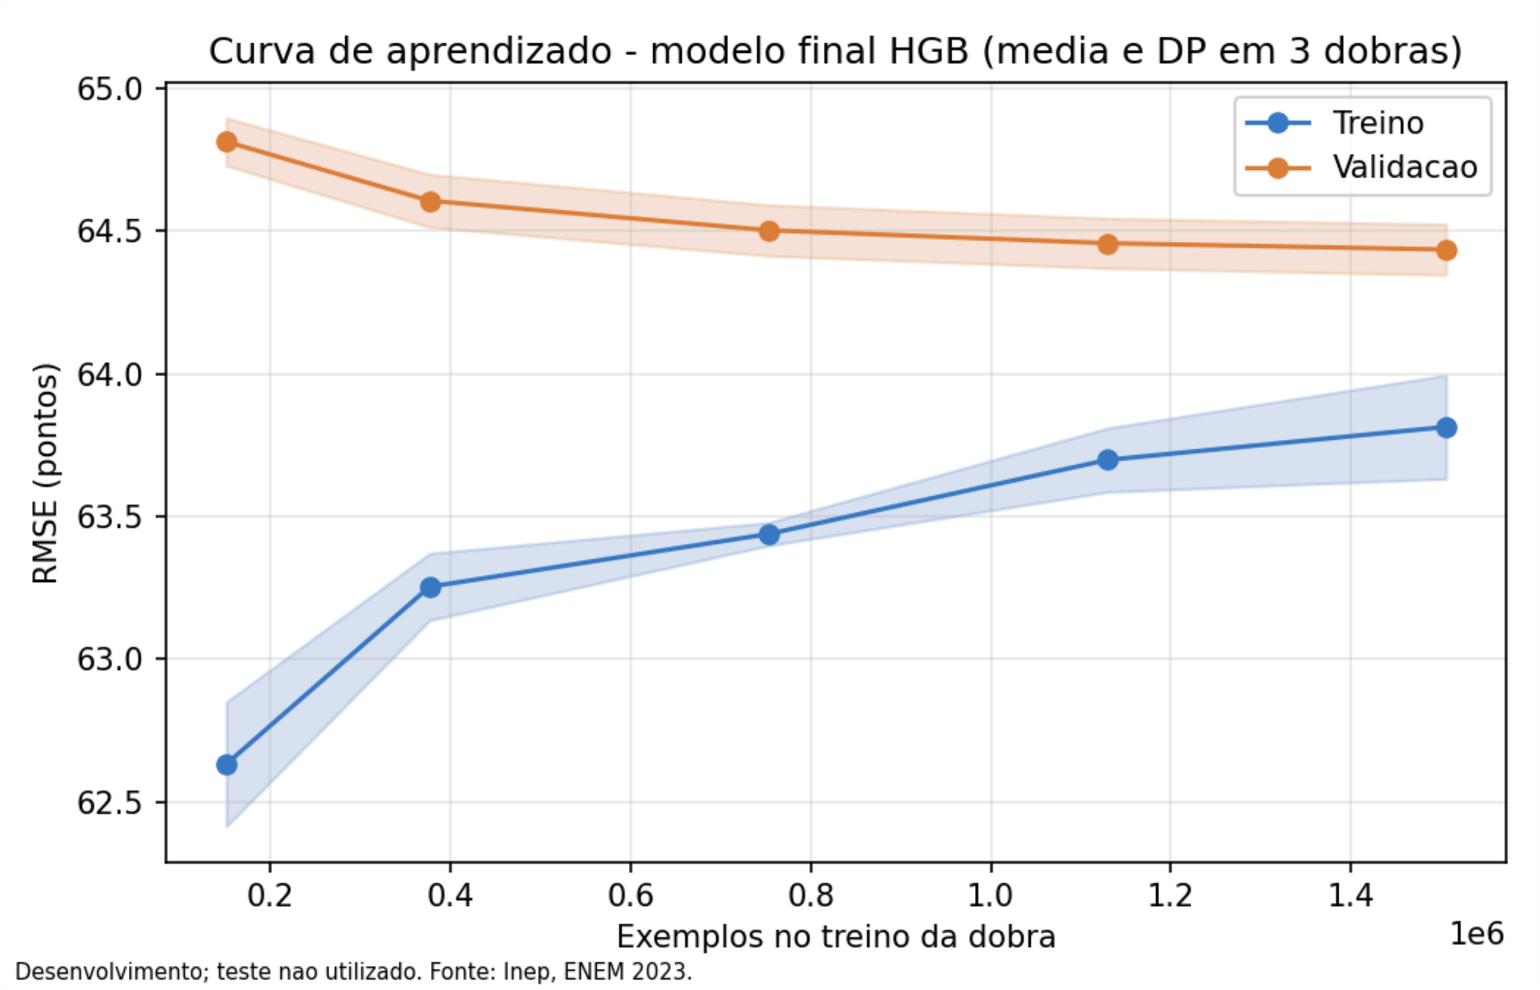
- learning_rate = 0,02
- max_features = 0,50
- max_iter = 4.000 (1.145 usadas) · max_leaf_nodes = 127
- min_samples_leaf = 300 · L2 = 1,0
- early stopping com validação interna de 10%

RESULTADO

No teste, o HGB-6 reduziu o RMSE em cerca de 11,01 pontos frente ao baseline e em 1,15 ponto frente à regressão linear.

A curva de aprendizado aponta estabilização, sem sobreajuste relevante

HGB-6 · média e desvio padrão entre três dobras; cada percentual se refere ao treino da dobra.



Desenvolvimento; teste nao utilizado. Fonte: Inep, ENEM 2023.

LEITURA DA CURVA

GAP TREINO × VALIDAÇÃO · 100%

0,6 pt

- A diferença cai de 2,2 para 0,6 ponto à medida que aumenta o treino.
- A validação melhora apenas 0,37 ponto entre 10% e 100%: a curva já está próxima da estabilidade.
- Não há evidência de sobreajuste forte no HGB-6

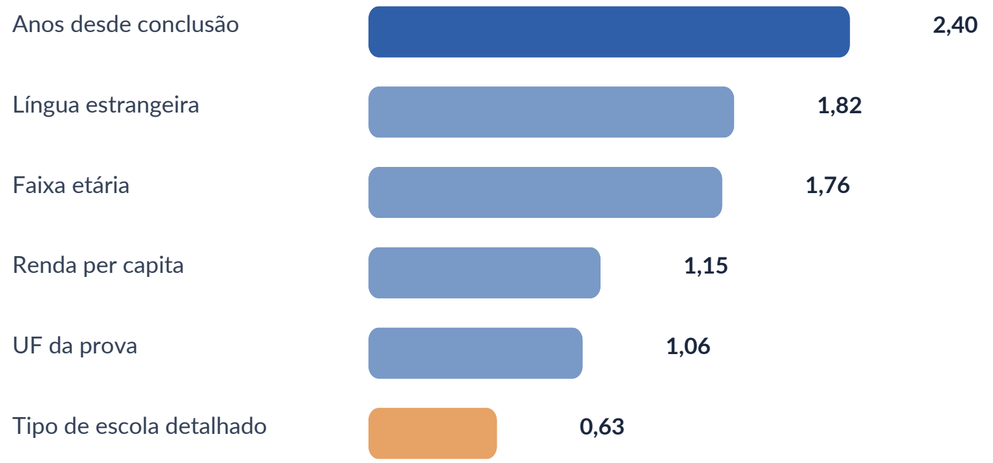
O modelo acerta melhor no centro e aproxima as previsões da média

Resultados do teste reservado do HGB-6; viés = nota observada − nota prevista.

FAIXA DE NOTA	N	RMSE	VIÉS
Zero	433	512,8	−510,9
0–400	36.217	134,7	−127,3
400–500	176.481	55,0	−38,7
500–600	278.114	43,8	+22,9
600–700	71.758	80,8	+72,2
700+	1.526	135,1	+130,9

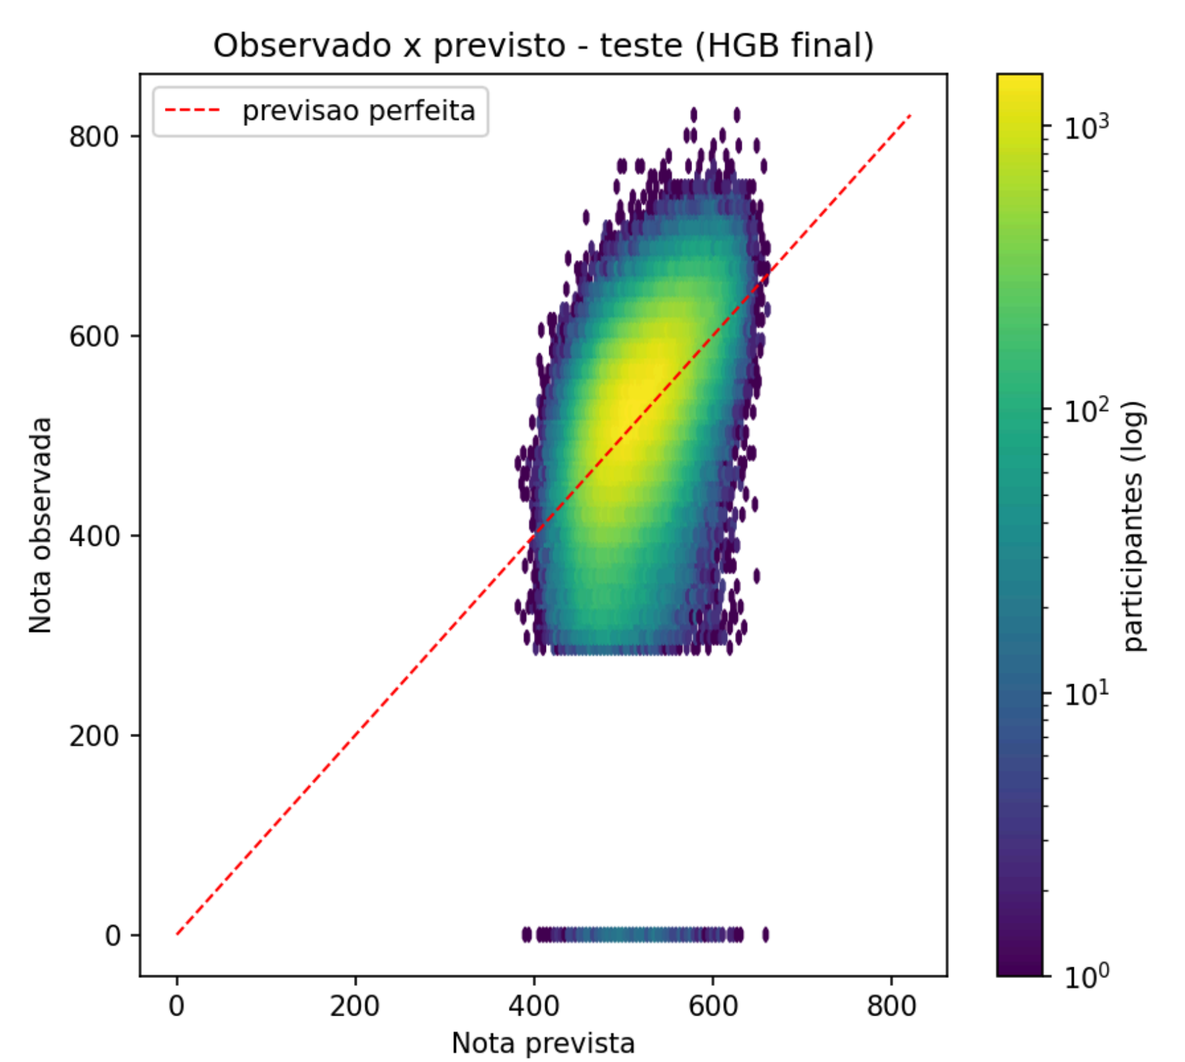
IMPORTÂNCIA POR PERMUTAÇÃO · TOP 6

Aumento do RMSE ao embaralhar cada feature



Importância calculada na validação da dobra 1 (100 mil participantes; 5 repetições), não no teste.

Observado x Previsto - HGB



Fonte: Inep, ENEM 2023. Celulas hexagonais agregam todos os registros do teste.

CONCLUSÃO | PROJETO 2

O melhor modelo não elimina os limites dos dados.

RESULTADO FINAL

O HGB-6 obteve RMSE 64,32, MAE 49,42 e R^2 0,271 no teste reservado de 564.529 participantes. O resultado ficou próximo da validação cruzada (RMSE 64,43 ± 0,08).

LIMITAÇÃO CENTRAL

As previsões vão de 382 a 663 (DP 39), enquanto as notas reais têm DP 75. O modelo funciona melhor na faixa 500–600 e tem dificuldade com desempenhos extremos dentro de perfis semelhantes.

A conclusão não é apenas “qual modelo venceu?”, mas o que o perfil disponível permite estimar, e o que permanece fora do alcance da previsão.